

KDT-17 3rd Team Project

# 쓰레기 이미지 12 종 분류

데이터 품질에서 시작한 딥러닝 이미지 분류

---

3 조 ( 김이박 )


팀장 이현중

팀원 김태경 · 박병찬

1

# 전체 파이프라인

네 단계 중 앞의 절반이 데이터 품질



## 데이터 품질 단계

원본을 그대로 학습에 투입하지 않음 . 중복 · 라벨 오류를 먼저 탐지하고 근거를 문서화 .

## 모델링 · 검증 단계

정제 데이터 위에서 모델 비교 · 성능 수치의 신뢰성을 통계로 검증 .

2

## 데이터 현황

재활용 쓰레기 사진을 12 개 클래스로 자동 분류

clothes  
34.3 %

shoes  
13.0 %

paper  
6.8 %

biological  
6.3 %

battery  
6.1 %

cardboard  
5.8 %

plastic  
5.6 %

white-glass  
5.0 %

metal  
5.0 %

trash  
4.5 %

green-glass  
4.0 %

brown-  
glass  
3.9 %

### 눈에 보이는 문제점

#### ① 클래스 불균형

Clothes 클래스 하나가 34.3%

최소 클래스의 약 8-9 배

#### ② 유리 3 종 구분


white, green, brown-glass

→ 형태 동일, 색만 상이

3

## 눈에 보이는 문제 ① : 클래스 불균형

클래스별 이미지 수 — 최다 · 최소 8.77 배 차이



# 34.3%

clothes 한 클래스가  
전체에서 차지하는 비중

# 8.77 배

최다 / 최소 클래스 비율

3

## 눈에 보이는 문제 ① : 클래스 불균형

정확도만 보면 안되는 이유

단순 기준

모든 입력을 clothes 라고만 답하는 모델

학습 없음 · 파라미터 0 개

정확도 0.3398

balanced accuracy 0.0833

macro-F1 0.0423

정확도 : 34%  
macro-F1 : 0.042

약 8 배 차이

다수 클래스 하나로만 예측 → 정확도 ↑

macro-F1 : 모든 클래스의 F1 을 동등 가중 평균  
→ 나머지 11 개를 전부 틀리면 즉시 붕괴 .

목적 = 모든 종류를 고르게 맞히기

4

## 눈에 보이는 문제 ② : 유리 색상 분류

형태가 같은 세 클래스를 가르는 단서는 색뿐



Brown-glass



Green-glass





White-glass

4

## 눈에 보이는 문제 ② : 유리 색상 분류

형태가 같은 세 클래스를 가르는 단서는 색뿐



**측정** 클래스당 250 장 표본 · HSV 변환 후 채도 40 미만 · 명도 30 미만 픽셀 제외 (배경 · 그림자 노이즈 차단)

**결정** 색이 정답 신호 → 증강에서 hue = 0.0 · saturation = 0.05 로 색 조작 최소화

5

# 검정 ① : 색 차이는 우연이 아닌가

겹침 계수는 기술통계 — 우연의 가능성은 설명하지 못함

## 가설

$H_0$  세 클래스의 색상 분포는 같다


$H_1$  세 클래스의 색상 분포는 다르다

## 방법 — 순열검정

유의수준  $\alpha = 0.05$

통계량 = 평균 겹침 계수  $\Rightarrow$  얼마나 겹치나?

라벨만 무작위로 섞어서 세 클래스의 평균 겹침 계수 측정  $\Rightarrow$  5000 회 반복



## 결론

$p = 0.0002$

유의수준  $\alpha$  보다 작다

$H_0$  기각  $\rightarrow H_1$  채택

유리 클래스마다 색이 다름

$\rightarrow$  증강에서 색 조작 X

6

## 이미지 품질 점검

학습 착수 전 확인 항목 4 가지

손상 파일

0 건

PIL verify 전수 검사  
학습 중 크래시 위험 없음

팔레트 (P) 모드

34 장

채널이 3 이 아니라 배치 파손  
convert("RGB") 필수

해상도 산포

51 ~ 888px

종횡비도 제각각  
resize 필요 (128 → 224)

색상 정보

유리 3 종

유일한 단서 = 색  
증강 시 건드리면 안됨

PART 2 · 이현중

# 폴더만 봐서는 알 수 없는 문제 & 모델 학습

같은 사진이 여러 장 · 신발 사진이 clothes 폴더에 혼입

## 중복 이미지 탐지

총 1.2 억 쌍의 이미지를 세 단계로 축소

전체 이미지 쌍

약 1.2억 쌍

픽셀 단위 전수 비교는 불가능

dHash 후보

Hamming  $\leq 5$

구조가 비슷한 쌍만 후보로

픽셀 검증 통과

평균차  $< 0.05$

32×32 RGB 실제 값으로 재확인

최종 근접중복

42그룹

육안으로 오탐 7그룹 제외

MD5 만으로는 리사이즈·재저장된 같은 사진을 잡을 수 없다

18 그룹

완전 동일 (MD5)

3 그룹

라벨이 충돌

42 그룹

근접 중복

7 그룹

육안 오탐 제외

# 탐지 결과를 눈으로 확인한다

알고리즘이 찾은 것과 사람이 판단한 것

## MD5로는 잡히지 않는 근접 중복

같은 그룹으로 묶인 세 장 · 파일 바이트는 서로 다르다



## 알고리즘이 같다고 판정한 오탐

흰 배경 + 세로 물체 구도가 같을 뿐, 서로 다른 칫솔 제품이다

trash357



trash384



trash413



## 진짜 근접 중복

육안으로는 동일한 사진인데 파일은 3 개

리사이즈 · 재저장으로 바이트가 달라져 MD5 로는 미탐지

## 알고리즘의 오탐


dHash · 픽셀 검증을 모두 통과했으나 실물은 서로 다른 칫솔 제품

흰 배경 + 세로 물체라는 제품 사진 구도만 동일

11

## 중복 데이터 제거 후 모델 테스트

모델이 바뀌어도 clotehs -> shoes 오탐지가 상위권에서 안 빠짐



## 라벨 오류 진단

모델을 데이터 라벨 검사 도구로 역이용

### 착안점

모델이 “확신하며 틀린” 예측은 둘 중 하나

정말 헛갈리는 사진이거나, 원본 라벨이 잘못됐거나

### 왜 두 단계로 나뉘냐

train 은 모델이 라벨을 그대로 암기

→ 라벨이 틀려도 그 오답을 재현해 “틀림” 으로 미검출

따라서 **2-fold out-of-fold** 로 “안 본 상태” 의 예측을 별도 생성

### 진단 결과

1 단계 · held-out

4,655 장   오분류 123 건

확신도 0.9 이상 59 건

2 단계 · train OOF

10,838 장   오분류 382 건

확신도 0.9 이상 145 건

---

합계 204 건 전수 육안 확인

# 실제로 어떤 사진이었나

모두 clothes 폴더에 들어 있던 파일

## 폴더가 알려주지 않는 라벨 오류

clothes 폴더에 들어 있던 신발 사진들 · 마지막 한 장은 반대 방향(반바지)

clothes3062 → shoes



clothes3330 → shoes



clothes5002 → shoes



clothes3545 → shoes



clothes2197 → shoes



shoes1826 → clothes



## 46 장

정정한 라벨 수

clothes → shoes 43

shoes → clothes 1

색상 · 재질 2

## 왜 중요한가

모델이 clothes 를 shoes 로 틀렸을 때

— 모델의 실수가 아니라 정답이 잘못돼 있던 것

모델을 개선해도 줄지 않던 이유

## 최종 정제 결과

중복 제거 & 라벨 정정 결과

15,515

원본



- 31

제외



15,48

4 최종

46 장

라벨 정정

완전 동일 중복 여분

16 장

그룹당 1 장만 유지

라벨이 충돌한 중복

6 장

같은 사진에 다른 라벨 → 양쪽 모두 제외

애매한 경계 사례

3 장

사람이 봐도 판단이 갈림

사진이 아닌 이미지

6 장

클립아트 · 목업 템플릿 · 스케치

→ 제외 이미지 총합

-31 장

완전 동일 중복 + 라벨 충돌 중복 + 애매한 경계 + 이미지

근접 중복 그룹

25 그룹

삭제하지 않고 같은 split 에 배치

라벨 정정

46 장

clothes → shoes 43, 그 외 3

15

## 라벨 정정 후 모델 학습

같은 모델 · 같은 설정에서 라벨 정정 후 데이터만 다시 학습

정제 전

0.9629

val macro-F1

clothes→shoes 8 건 · 1 위



라벨 정정 후

0.9731

val macro-F1

clothes→shoes 3 건 · 공동 3 위

모델을 조금도 바꾸지 않고 라벨만 정정

val(2,318 장) 재평가 결과 다른 오분류 쌍보다 압도적으로 많던 clothes→shoes 가 공동 3 위로 내려감

## 모델 비교

베이스라인 CNN vs 전이학습 · 128px · 검증셋 macro-F1 기준

val macro-F1

Baseline CNN

0.6521

EfficientNetV2-S (백본 동결)

0.8089

EfficientNetV2-S (224px 미세조정)

0.9840

베이스 라인 대비 val macro-F1 score

**+0.32**

ImageNet 128 만 장에서 학습한 특징이 쓰레기 사진에도 그대로 적용됐다 .

최종 채택

EfficientNetV2-S unfreeze · lr 5e-5 (128px 기준)



-> 해상도를 224px 로 올리면서 학습률도 다시 탐색

# 해상도 튜닝

128px vs 224px— 128px, 검증셋 (val) macro-F1 기준

128px 224px

가로축 0.90 ~ 1.00 구간 확대



개선은 약한 클래스에서

128px 에서 구분이 힘들던 재질 관련 분류 plastic +0.047 · metal +0.028 · brown-glass +0.021 의 상승

# 시행착오

128px 에서 최적이던 학습률이 224px 에서는 최적이 아님

## 처음 방법

128px 기준으로 선택한 학습률

|             |                          |
|-------------|--------------------------|
| <b>5e-5</b> | <b>0.9731</b> ← 128px 최적 |
| 1e-4        | 0.9600                   |
| 3e-4        | 0.9658                   |

입력을 224px 로 올린 뒤 같은 학습률 (5e-5) 을 그대로 적용  
→ val macro-F1 0.9787 에 정체 . 128px 최적값이 224px 에서는  
최적이 아님

## 고친 방법

224px 에서 학습률 재탐색

|             |               |           |
|-------------|---------------|-----------|
| <b>1e-4</b> | <b>0.9840</b> | <b>채택</b> |
| 5e-5        | 0.9787        | 128px 최적값 |
| 3e-4        | 0.9738        |           |

조건이 바뀌면 하이퍼파라미터도 재선택해야 한다  
— 해상도를 바꿨으면 학습률도 다시 탐색해야 한다는 뜻

## 모델 선정과 튜닝의 근거

같은 설정으로 시드 5 회 반복해서 확인한 노이즈 기준선

**$\pm 0.0046$**

시드 5 회 test macro-F1 표준편차

**0.9596~0.9699**

5 회 반복 test macro-F1 범위

**이 폭보다 작은 차이**

= 개선이 아니라 우연일 수 있음

정제 전후 test 점수 차이

**$\pm 0.001 \sim 0.003$**

노이즈 안 ( $\pm 0.0046$ ) → 판단 불가

학습률 5e-5 vs 3e-4

**+0.0073**

신뢰구간이 0 포함 → 판단 불가 (5e-5 vs 1e-4 는  $p=0.024$  로 유의)

224px 3lr 앙상블 vs 단일모델

**+0.0006**

노이즈보다 훨씬 작음 → 판단 불가

clothes→shoes 오분류 감소

**20 건대 → 2~4 건**

노이즈보다 훨씬 큼 · 3 번의 독립 실행 모두 재현 → 진짜 효과

**최종 결론**

‘정확도가 올랐다’가 아니라 ‘오분류 패턴이 라벨오류성에서 재질혼동성으로 바뀌었다’  
숫자보다 패턴 변화가 더 믿을 수 있는 증거

PART 3 · 박병찬

# 숫자의 신뢰성을 확인하는 단계

test 는 여기서 단 한 번만 사용



20

## 최종 성능

EfficientNetV2-S (unfreeze, 224px, lr 1e-4) · test 2,334 장

0.9859

accuracy

0.9787

macro-F1


0.9790

macro-recall

0.9998

macro-AUC

클래스별 F1



### 가장 약한 세 클래스

plastic 0.932 (정밀도 0.918)  
white-glass 0.948 (재현율 0.940)  
metal 0.971 (정밀도 0.943)

재질 경계가 모호한 클래스.  
정제로 해결되는 문제가 아님.

**선정 규칙** 모델 선정은 검증셋 macro-F1 으로만 · test 는 이 한 번뿐 . 남은 약점은 재질 경계가 모호한 클래스에 집중 .

## 21 검정 ② 두 지표의 격차는 유의한가

accuracy 0.9859 · macro-F1 0.9787 의 차이가 표본 변동일 가능성 검토

### 가설

H0 두 지표의 차이는 0

H1 accuracy 가 더 큼

### 방법 — 부트스트랩

test 2,334 장에서 복원추출로 동일 크기 표본을 2,000 회 생성 → 각 표본에서 두 지표의 차이를 계산 . 95% 신뢰구간이 0 을 포함하지 않으면 H0 기각 .


### 결론

**하한 0.0046**


**H0 기각**

2,000 회 중 뒤집힌 사례 없음

두 지표의 부트스트랩 분포



구간이 0을 포함하지 않는다 → H0 기각




22

# 무엇을 무엇으로 틀렸나

test 2,334 장 · 오분류 33 건

test 혼동행렬 · 2,334장 중 오분류 33건



## 읽는 법

- 행 = 실제 라벨
- 열 = 모델 예측
- 진할수록 그 행에서 차지하는 비중이 큼
- 대각선 밖 숫자가 오분류

## 눈에 띄는 것

대각선이 압도적으로 진함 .  
clothes 793 장 전량 정답 .

남은 33 건은 재질 · 색상 혼동에 집중 .  
white-glass ↔ plastic 이 9 건으로 최다이고 ,  
나머지는 대부분 metal 관련 .

# 그래서 무엇이 헛갈렸나

가장 많은 조합 9 건 중 확신도 상위 6 장


white-glass → plastic · 확신도 0.95



white-glass → plastic · 확신도 0.82 plastic → white-glass · 확신도 0.75



plastic → white-glass · 확신도 0.62



plastic → white-glass · 확신도 0.60



white-glass → plastic · 확신도 0.58



## 투명 유리 vs 투명 페트

사진만으로는 사람도 구분하기 어렵다. 왼쪽 위는 실제 유리병인데 모델이 확신도 0.95 로 plastic 이라고 답했다.

## 남은 오류의 성격

정제로 해결되는 문제가 아니다.  
라벨도 맞고 사진도 정상이다.

재질 자체가 시각적으로 구분되지 않는 경우 —  
문제의 본질적 난이도

## 정제를 통해 얻은 것

정확도는 거의 그대로 , 오분류 유형은 변화

정제 전

**clothes → shoes 가 실험 내내 1 위**

20 건대를 계속 유지 · 모델을 개선해도 감소하지 않음 →  
원인이 모델이 아니라 원본 라벨이었기 때문 .

정제 후 상위 오분류

|                        |            |
|------------------------|------------|
| white-glass → plastic  | 5 건        |
| plastic → white-glass  | 4 건        |
| cardboard → metal      | 2 건        |
| white-glass → metal    | 2 건        |
| <b>clothes → shoes</b> | <b>0 건</b> |

## EDA 단계에서 이미 확인한 위험

평균 채도 / 유효 색상 픽셀 비율

|                    |              |             |
|--------------------|--------------|-------------|
| brown-glass        | 60.85        | 0.37        |
| green-glass        | 63.68        | 0.40        |
| <b>white-glass</b> | <b>19.78</b> | <b>0.14</b> |


EDA 에서 white-glass 의 채도가 다른 유리의 3 분의 1 임을 확인 .  
색 정보 부재 → 질감 · 반사에 의존 → 금속 광택과 중첩 가능 . 이  
위험을 사전 파악한 상태로 모델링에 착수했고 , 실제 오분류가 예상과  
일치 .

25

# 얼마를 사람에게 넘길 것인가

운영 임계값 결정의 근거가 되는 분포


모델은 대부분 확신하고, 확신할 때는 맞는다



## 정답과 오답의 분포가 갈림

정답 2,301 장은 확신도 1.0 근처에 집중 · 오답 33 건은 넓게 분산.

얼마를 사람이 확인할 것인가



## 현장에 적용하면

0.3%(8 장) 만 사람이 확인 → 나머지는 98.8% 정확도로 자동 분류.

# 임계값 조정은 효과가 있었나

선택은 검증셋에서 · test 는 한 번만

## 검정 ③ 클래스별 가중 argmax

소수 클래스에 유리한 가중치를 곱해 argmax 를 이동 . 검증셋에서 선택된 최적 계수는 0.00.

|       | 조정 맞춤 | 조정 틀림 |
|-------|-------|-------|
| 기본 맞춤 | 2,301 | 0     |
| 기본 틀림 | 0     | 33    |

불일치 0 쌍 — 예측 변화 없음 → 검정 자체가 성립하지 않음

## 검정 ④ 확신도 기반 판단 보류

확신도가  $\tau$  미만이면 사람에게 이관 . 자동 처리 구간의 정확도가 전체보다 유의하게 높은지 부트스트랩으로 검증 .

|                                   |                  |
|-----------------------------------|------------------|
| 전체 정확도                            | 0.9859           |
| 자동 처리 정확도                         | 0.9884           |
| 차이 95% CI                         | [0.0008, 0.0047] |
| 0 을 포함하지 않음 — H0 기각 · 보류 규칙 작동 확인 |                  |

## 여기서 가장 중요한 것은 ③ 이 실패했다는 사실

검증셋에서는 가중치가 macro-F1 을 상승시켰으나 test 에서는 예측 변화 0 장 → 이득이 검증셋에 과적합되어 있었다는 뜻 .

test 확률에서 임계값을 골랐다면 반드시 미세한 개선이 나왔을 것이고 그 개선은 허구 . 검증셋에서 고르고 test 에 한 번만 적용했기에 확인 가능 .

27

# 사람이 확인할 8 장

확신도 0.53 미만 · 전체의 0.3%

plastic (정답) · 확신도 0.40



battery → plastic · 확신도 0.44



cardboard → battery · 확신도 0.46



trash → plastic · 확신도 0.49




white-glass → plastic · 확신도 0.50



shoes → biological · 확신도 0.49



plastic (정답) · 확신도 0.52



plastic → white-glass · 확신도 0.53



## 보류가 곧 오답은 아니다

초록 테두리 2 장은 정답인데도 확신도가 낮아 보류됐다. 자신 없으면 맞았어도 넘긴다는 것이 이 규칙의 설계다.

## 라벨 오류까지 검출

오른쪽 위 기저귀는 trash 로 라벨돼 있지만 clothes 가 맞다고 이미 판정된 파일이다. 모델이 확신하지 못한 이유가 라벨 오류였던 셈이다.

무엇을 했고 · 무엇을 못 했는가

## 결론

성능은 모델에서,  
신뢰는 데이터에서

0.652 → 0.984

모델을 바꿔서 얻은 것

20 건대 → 0 건

데이터를 고쳐서 얻은 것

재질 혼동은 해상도를 224px 로 올려 개선 — 오분류 53 건 → 33 건

## 남은 한계

### 1 탐지 임계값은 임의값

Hamming 5 · 픽셀차 0.05 는 시행착오로 결정 . 값  
변경 시 매번 재학습 필요 .

### 2 라벨 검수 범위가 고르지 않음

모델이 확신하며 틀린 것만 후보로 추출 → 못 배우는  
유형의 오류는 미검출 .

### 3 단일 시드 · 단일 학습

0.005 안팎의 차이는 실행 간 변동 폭 이내일 수 있음 .

# 감사합니다

---

3 조 ( 김이박 ) — 김태경 · 이현중 · 박병찬