

PART 3 발표 자료

평가와 해석

박병찬 · 슬라이드 22 ~ 32 · 약 7분 30초

3조 (김이박) — 쓰레기 이미지 12종 분류

이 파트에서 반드시 전달할 네 가지

1. 숫자를 그냥 믿지 않았다

정확도 0.9859 와 macro-F1 0.9787 의 격차가 우연인지 부트스트랩으로 검정했다. 신뢰구간 [0.0046, 0.0102] 로 0 을 포함하지 않아 H_0 를 기각했다.

2. EDA 에서 확인해둔 위험이 실제로 나타났다

white-glass 의 채도가 다른 유리의 3분의 1 이라는 사실을 EDA 에서 미리 측정했고, 실제 오분류가 white-glass 와 plastic 사이에 몰렸다.

3. 기법이 통하지 않는다는 것도 결과로 보고했다

임계값 조정은 test 예측을 한 장도 바꾸지 못했다. 검증셋에서 골랐기 때문에 이 사실을 확인할 수 있었다. 이 파트에서 가장 강한 대목이다.

4. 숫자를 사진으로 바꿔 보여준다

26번은 오분류 9건의 실물, 30번은 사람에게 넘어가는 8장 전량이다. 특히 30번의 기저귀 한 장 — 모델이 확신하지 못한 이유가 라벨 오류였다는 것이 이 파트에서 가장 예상 밖의 결과다.

진행 흐름


22	전환	10초	앞 발표자에게서 넘겨받는 지점
23	최종 성능	55초	test 지표 4개 + 약한 클래스 3개
24	검정 2 · 부트스트랩	55초	지표 격차가 우연이 아님
25	무엇을 무엇으로 틀렸나	55초	무엇을 무엇으로 틀렸나
26	오분류 실물 (사진)	45초	숫자 9건을 사진으로 — 투명 유리 vs 페트
27	정제를 통해 얻은 것	60초	EDA 와 연결 — 하이라이트 1
28	얼마를 사람에게 넘길 것인가	50초	운영 임계값의 근거

29	임계값 조정은 효과가 있었나	90초	실패 보고 — 하이라이트 2
30	사람이 확인할 8장 (사진)	45초	라벨 오류까지 걸러냄 — 하이라이트 3
31	정리	40초	결론 + 한계
32	마무리	10초	감사 인사 · 질의응답 중 띄워둠

시간 관리 29번에 90초를 배정했다. 앞에서 밀리면 23·25번을 각 10초씩 줄이고 29·30번은 그대로 두는 것이 낫다 — 그 두 장이 이 파트의 값어치를 결정한다.

슬라이드 22 · 10초

전환




“ 지금까지 모델을 만들었으니, 이제 그 숫자가 진짜인지 확인할 차례입니다. ”

“ test는 여기서 단 한 번만 사용합니다. ”

슬라이드 23 · 55초

최종 성능



“ 최종 모델은 EfficientNetV2-S 미세조정에 입력 224px, 학습률 1e-4입니다. test 2,334장에 적용한 결과입니다. ”

“ 정확도 0.9859, 주 지표인 **macro-F1은 0.9787**, macro-AUC는 0.9998입니다. ”

“ 아래는 클래스별 F1을 낮은 순으로 정렬한 것입니다. 왼쪽 두 개가 가장 약합니다. ”

“ **plastic이 0.932로 최저이고, white-glass가 0.948입니다.** metal은 재현율이 1.000인데 정밀도가 0.943입니다 — 애매하면 metal이라고 답하는 경향이 남아 있습니다. ”

“ 이 클래스들은 재질 경계가 모호합니다. **정제로 해결되는 문제가 아닙니다.** 페트병과 캔, 종이팩과 판지는 사람이 봐도 헷갈립니다. ”

슬라이드 24 · 55초

검정 2 두 지표의 격차는 유의한가

21 검정 ② 두 지표의 격차는 유의한가

accuracy 0.9859 · macro-F1 0.9787 의 차이가 표본 변동일 가능성 검토

가설

H0 두 지표의 차이는 0
H1 accuracy 가 더 큼

방법 — 부트스트랩


test 2,334 장에서 복원추출로 동일 크기 표본을 2,000 회 생성 → 각 표본에서 두 지표의 차이를 계산 . 95% 신뢰구간이 0 을 포함하지 않으면 H0 기각 .

결론

하한 0.0046

H0 기각

2,000 회 중 뒤집힌 사례 없음



“ 정확도 0.9859, macro-F1 0.9787. 차이가 0.7%p 정도입니다. 이게 진짜 차이인지, 아니면 test 2,334장을 어쩌다 그렇게 뽑아서 생긴 우연인지 확인해야 합니다. ”

“ 귀무가설은 "두 지표의 차이가 0이다"입니다. ”

“ 방법은 부트스트랩입니다. test에서 복원추출로 같은 크기의 표본을 2,000번 만들고, 매번 두 지표의 차이를 계산합니다. 그 차이 분포의 95% 신뢰구간이 0을 포함하지 않으면 귀무가설을 기각합니다. ”


“ 왼쪽 그래프를 보시면 두 지표의 분포가 거의 겹치지 않습니다. 오른쪽이 그 차이의 분포인데, 신뢰구간이 0.0046에서 0.0102입니다. ”

“ 0을 포함하지 않습니다. 귀무가설을 기각합니다. ”

“ 2,000번 재표본을 뽑았는데 두 지표가 뒤집힌 경우가 한 번도 없었다는 뜻입니다. 앞에서 김태경 팀원이 말한 "정확도가 소수 클래스 실패를 가린다"가 최종 모델에서도 통계적으로 확인된 겁니다. ”

슬라이드 25 · 55초

무엇을 무엇으로 틀렸나



“ 어떤 클래스를 어떤 클래스로 틀렸는지 혼동행렬로 보겠습니다. 행이 실제 라벨, 열이 모델 예측입니다. ”

“ 먼저 **대각선이 압도적으로 진합니다**. clothes는 793장을 전부 맞혔습니다. ”

“ 2,334장 중 오분류가 33건뿐입니다. ”

“ 그런데 그 33건이 어디에 몰려 있는지가 중요합니다. **white-glass와 plastic 사이가 9건으로 최다입니다**. 투명 유리병과 투명 페트병이죠. ”

“ 나머지도 대부분 metal 관련입니다. cardboard에서 metal로 2건, white-glass에서 metal로 2건입니다. ”

“ 즉 남은 오류는 **재질계에 몰려 있습니다**. 이건 데이터 문제가 아니라 문제 자체의 난이도입니다. ”

슬라이드 26 · 45초

그래서 무엇이 헛갈렸나

23 그래서 무엇이 헛갈렸나

가장 많은 조합 9 건 중 확신도 상위 6 장

white-glass → plastic · 확신도 0.95




white-glass → plastic · 확신도 0.82



plastic → white-glass · 확신도 0.75



plastic → white-glass · 확신도 0.62



plastic → white-glass · 확신도 0.60



white-glass → plastic · 확신도 0.58



투명 유리 vs 투명 페트

사진만으로는 사람도 구분하기 어렵다. 왼쪽 위는 실제 유리병인데 모델이 확신도 0.95로 plastic 이라고 답했다.

남은 오류의 성격

정제로 해결되는 문제가 아니다. 라벨도 맞고 사진도 정상이다.

재질 자체가 시각적으로 구분되지 않는 경우 — 문제의 본질적 난이도

“방금 표에서 white-glass 와 plastic 사이가 9건이라고 말씀드렸는데, 실제로 어떤 사진인지 보시겠습니다.”

“왼쪽 위부터 보시면요. **이건 실제 유리병입니다.** 그런데 모델이 확신도 0.95로 plastic 이라고 답했습니다.”

“오른쪽 위는 반대로 페트병인데 white-glass 로 봤고요. 아래 가운데도 페트병입니다.”

“**사진만 놓고 보면 사람도 구분하기 어렵습니다.** 투명하고, 목이 있고, 뚜껑이 달려 있습니다. 재질은 만져봐야 아는 건데 모델은 사진밖에 못 봅니다.”

“**그래서 이 오류들은 정제로 해결되는 문제가 아닙니다.** 라벨도 맞고 사진도 정상입니다. 재질 자체가 시각적으로 구분되지 않는 경우고, 이건 문제의 본질적 난이도입니다.”

(왼쪽 위 한 장만 손으로 짚어도 충분합니다. 나머지는 청중이 알아서 봅니다.)

슬라이드 27 · 60초

정제를 통해 얻은 것

24 정제를 통해 얻은 것

정확도는 거의 그대로, 오분류 유형은 변화

정제 전

clothes → shoes 가 실험 내내 1 위

20 건대를 계속 유지 · 모델을 개선해도 감소하지 않음 →
원인이 모델이 아니라 원본 라벨이었기 때문.

정제 후 상위 오분류

white-glass → plastic	5 건
plastic → white-glass	4 건
cardboard → metal	2 건
white-glass → metal	2 건
clothes → shoes	0 건

EDA 단계에서 이미 확인한 위험

평균 채도 / 유효 색상 픽셀 비율

brown-glass	60.85	0.37
green-glass	63.68	0.40
white-glass	19.78	0.14

EDA 에서 white-glass 의 채도가 다른 유리의 3 분의 1 임을 확인.
색 정보 부재 → 질감 · 반사에 의존 → 금속 광택과 중첩 가능. 이
위험을 사전 파악한 상태로 모델링에 착수했고, 실제 오분류가 예상과
일치.

“ 그런데 여기서 흥미로운 게 있습니다. 정제 효과가 정확도 숫자가 아니라 틀리는 방식에서 드러났습니다. ”

“ 정제 전에는 clothes를 shoes로 틀리는 게 실험 내내 1위였습니다. 20건대를 계속 유지했습니다. 모델을 아무리 개선해도 줄지 않았는데, 원인이 모델이 아니라 원본 라벨이었기 때문입니다. ”

“ 정제와 해상도 개선을 거친 지금은 top-10에서 아예 사라졌습니다. 상위 오분류가 전부 재질·색상 혼동으로 바뀌었습니다. ”

“ 그리고 오른쪽이 이 발표에서 저희가 가장 하고 싶은 이야기입니다. ”

“ 이 오분류는 EDA 단계에서 이미 확인해둔 위험이었습니다. ”


“ 앞서 김태경 팀원이 보여드린 표를 다시 보시면, white-glass의 채도가 19.78로 다른 유리의 3분의 1이었죠. 유효 색상 픽셀 비율도 0.14로 절반 이하였고요. ”

“ 색 정보가 없으면 모델은 질감과 반사에만 의존하게 되고, 그것이 금속 광택과 겹칠 수 있습니다. 저희는 이 위험을 미리 파악한 상태에서 모델링에 들어갔고, 실제 오분류가 그 예상과 일치했습니다. ”

“ EDA를 형식적으로 넘기지 않고 정량적으로 확인해둔 것이 결과 해석에 그대로 쓰인 셈입니다. ”

슬라이드 28 · 50초

얼마를 사람에게 넘길 것인가



“마지막으로 모델이 얼마나 확신하는지 봤습니다.”

“왼쪽 히스토그램에서 초록이 정답, 주황이 오답입니다. 정답 2,301장은 확신도 1.0 근처에 몰려 있고, 오답 33건은 넓게 퍼져 있습니다.”

“두 분포가 같린다는 건 중요합니다. 확신도만 보고도 “이건 사람이 다시 봐야 한다”를 걸러낼 수 있다는 뜻이기 때문입니다.”

“오른쪽이 그 결과입니다. 임계값을 올리면 자동 처리 비율은 줄지만 자동 처리한 것의 정확도는 올라갑니다.”

“저희가 검증셋에서 고른 지점은 0.53입니다. 여기서 들어온 사진의 0.3%, 단 8장만 사람이 확인하면 나머지는 98.8% 정확도로 자동 분류됩니다.”

“쓰레기 분류라는 실제 문제에 가장 잘 맞는 형태의 결론입니다.”

슬라이드 29 · 90초

임계값 조정은 효과가 있었나

26 임계값 조정은 효과가 있었나

선택은 검증셋에서 · test 는 한 번만

검정 ③ 클래스별 가중 argmax

소수 클래스에 유리한 가중치를 곱해 argmax 를 이동 . 검증셋에서 선택된 최적 계수는 0.00.

	조정 맞춤	조정 틀림
기본 맞춤	2,301	0
기본 틀림	0	33

불일치 0 쌍 — 예측 변화 없음 → 검정 자체가 성립하지 않음

검정 ④ 확신도 기반 판단 보류

확신도가 tau 미만이면 사람에게 이관 . 자동 처리 구간의 정확도가 전체보다 유의하게 높은지 부트스트랩으로 검증 .

전체 정확도	0.9859
자동 처리 정확도	0.9884
차이 95% CI	[0.0008, 0.0047]

0 을 포함하지 않음 — H0 기각 · 보류 규칙 작동 확인

여기서 가장 중요한 것은 ③ 이 실패했다는 사실

검증셋에서는 가중치가 macro-F1 을 상승시켰으나 test 에서는 예측 변화 0 장 → 이득이 검증셋에 과적합되어 있었다는 뜻 .

test 확률에서 임계값을 골랐다면 반드시 미세한 개선이 나왔을 것이고 그 개선은 허구 . 검증셋에서 고르고 test 에 한 번만 적용했기에 확인 가능 .

“ 마지막 검정 두 개입니다. 임계값 조정이 실제로 성능을 올렸는지 확인했습니다. ”

“ 먼저 왼쪽, 검정 3입니다. 소수 클래스에 유리한 가중치를 곱해서 argmax를 미는 방법입니다. 검증셋에서 최적 계수를 찾았더니 0.00이 나왔습니다. 조정을 아예 하지 말라는 뜻이죠. ”

“ 그래도 test에 적용해봤습니다. 표를 보시면 2,301장이 둘 다 맞고, 33장이 둘 다 틀렸습니다. 예측이 바뀐 게 한 장도 없습니다. ”

“ McNemar 검정은 두 예측이 다른 경우만 보는데, 다른 경우가 0건이라 검정 자체가 성립하지 않습니다. ”

“ 오른쪽, 검정 4입니다. 확신도가 기준 미만이면 사람에게 넘기는 방식이죠. 자동 처리 구간의 정확도가 전체보다 유의하게 높은지 부트스트랩으로 확인했습니다. 전체 0.9859, 자동 처리분 0.9884, 차이의 신뢰구간이 0.0008에서 0.0047입니다. 0을 포함하지 않으니 귀무가설을 기각합니다. 보류 규칙은 작동합니다. ”

“ 그런데 이 슬라이드에서 가장 중요한 건 3이 실패했다는 사실입니다. ”

“ 검증셋에서는 가중치가 macro-F1을 올렸습니다. 그런데 test에서는 예측이 한 장도 안 바뀌었습니다. 이득이 검증셋에 과적합되어 있었던 겁니다. ”

“ 만약 저희가 test 확률을 보고 임계값을 골랐다면 어땠을까요. 반드시 미세한 개선이 나왔을 겁니다. 그리고 그 개선은 허구였을 겁니다. ”

“ 검증셋에서 고르고 test에 딱 한 번만 적용했기 때문에 이 사실을 확인할 수 있었습니다. 기법이 통했다는 결과보다, 통하지 않는다는 걸 정직하게 확인한 결과가 방법론적으로 더 값어치 있다고 생각합니다. ”

(이 슬라이드에서 시간을 충분히 쓰세요. 발표 전체에서 가장 강한 부분입니다.)

슬라이드 30 · 45초

사람이 확인할 8장

27 사람이 확인할 8 장

확신도 0.53 미만 · 전체의 0.3%



보류가 곧 오답은 아니다

초록 테두리 2 장은 정답인데도 확신도가 낮아 보류됐다. 자신 없으면 맞았어도 넘긴다는 것이 이 규칙의 설계다.

라벨 오류까지 검출

오른쪽 위 기저귀는 trash 로 라벨돼 있지만 clothes 가 맞다고 이미 판정된 파일이다. 모델이 확신하지 못한 이유가 라벨 오류였던 셈이다.

“방금 0.3%, 8장이라고 말씀드렸는데 그 여덟 장이 이겁니다.”

“주황 테두리가 틀린 것, 초록이 맞힌 것입니다.”

“먼저 초록 두 장을 보시면 정답인데도 보류됐습니다. 확신도가 0.40, 0.52로 낮았기 때문입니다. 보류가 곧 오답은 아닙니다. 자신 없으면 맞았어도 사람에게 넘긴다는 게 이 규칙의 설계입니다.”

“그리고 오른쪽 위 기저귀를 봐주세요. 라벨은 trash 인데 모델은 plastic 이라고 했고 확신도가 0.49입니다.”

“그런데 이 파일은 저희가 이미 라벨 오류 후보로 지목해둔 것입니다. 바다생물 무늬 패브릭 기저귀라 clothes 가 맞다고 판정했던 파일이죠.”

“모델이 확신하지 못한 이유가 라벨 오류였던 겁니다. 확신도 기반 보류가 모델의 실수뿐 아니라 정답이 잘못된 경우까지 걸러낸 셈입니다.”

(기저귀 한 장을 짚으면서 말하세요. 이 파트에서 가장 예상 못한 결과입니다.)

슬라이드 31 · 40초

정리

28 정리

무엇을 했고 · 무엇을 못 했는가

결론

**성능은 모델에서 ,
신뢰는 데이터에서**

0.652 → 0.984
모델을 바꿔서 얻은 것

20 건대 → 0 건
데이터를 고쳐서 얻은 것

재질 혼동은 해상도를 224px 로 올려 개선 — 오분류 53 건 → 33 건

남은 한계

- 탐지 임계값은 임의값**
Hamming 5 · 픽셀차 0.05 는 시행착오로 결정. 값 변경 시 매번 재학습 필요.
- 라벨 검수 범위가 고르지 않음**
모델이 확신하며 틀린 것만 후보로 추출 → 못 배우는 유형의 오류는 미검출.
- 단일 시드 · 단일 학습**
0.005 안팎의 차이는 실행 간 변동 폭 이내일 수 있음.

실패도 결과 주요 주장 4 개에 통계검정을 붙였고, 그중 하나는 효과가 없었다. 감추지 않고 그대로 보고

“ 정리하겠습니다. ”

“ 성능은 모델에서 왔고, 신뢰는 데이터에서 왔습니다. ”

“ 밑바닥 CNN 0.652에서 224px 전이학습 0.984까지 올린 건 모델을 바꿔서 얻은 것입니다. 반면 clothes → shoes 오분류를 20건대에서 0건으로 만든 건 모델을 전혀 건드리지 않고 데이터만 고쳐서 얻은 결과입니다. ”

“ 둘 중 하나만으로는 지금 결과가 나오지 않았습니다. ”

“ 오른쪽은 저희가 아직 못 한 것들입니다. ”

“ 근접중복 탐지 임계값은 시행착오로 정한 값이고, 라벨 검수는 클래스마다 고르지 않으며, 시드 하나로만 학습했습니다. 시드 5회 반복에서 test macro-F1이 ± 0.0046 흔들렸으니 0.005 안팎의 차이는 그 안에 있을 수 있습니다. 세 가지 다 추가 학습 시간이 필요해서 이번 범위에서는 해결하지 못했습니다. ”

“ 마지막으로 한 가지만 더 말씀드리겠습니다. ”

“ 저희는 주요 주장 네 개에 통계 검정을 붙였습니다. 유리 색상 차이, 지표 격차, 임계값 조정, 확신도 보류입니다. ”


“ 그중 하나는 예측을 바꾸지 못했습니다. 임계값 조정입니다. test 예측이 한 장도 달라지지 않았습니다. ”

“ 그것도 결과로 보고했습니다. 감추면 나머지 세 개도 믿을 수 없기 때문입니다. ”

(결론 한 문장을 먼저 말하고 숫자 두 개로 뒷받침하세요. 한계는 빠르게 넘어가되 빠뜨리지 마세요.)

슬라이드 32 · 10초

마무리



“ 이상 3조 발표를 마치겠습니다. 감사합니다. ”

(질의응답 동안 이 화면을 띄워둡니다. 산출물 목록이 보이므로 코드 관련 질문을 유도하기 좋습니다.)

이 파트에서 나올 만한 질문

Q. 검정 3은 실패했는데 왜 발표에 넣었나요?

→ 이 프로젝트에서 가장 의미 있는 결과 중 하나라고 봅니다. 검증셋에서는 개선이 있었는데 test에서는 예측이 한 장도 안 바뀌었습니다. 임계값 조정의 이득이 검증셋에 과적합될 수 있다는 걸 보여줍니다. 만약 test에서 임계값을 골랐다면 개선이 나왔을 것이고 그건 허구였을 겁니다.

Q. macro-AUC 가 0.9998 이면 거의 완벽한데, 왜 macro-F1 은 0.9787 인가요?

→ AUC 는 임계값과 무관하게 순위를 얼마나 잘 매기는지를 봅니다. 정답 클래스의 확률이 다른 클래스보다 높기만 하면 됩니다. macro-F1 은 argmax 로 실제 판정을 내린 결과라 더 엄격합니다. 즉 순위는 거의 완벽한데 최종 판정에서 33건이 뒤집힌 겁니다.

Q. 오분류 33건이면 충분히 좋은데 왜 한계를 강조하나요?

→ 33건이 어디에 몰려 있는지가 중요하기 때문입니다. white-glass 와 plastic 사이가 9건인데 이건 투명 유리병과 투명 페트병이라 실제 분리수거에서도 자주 섞이는 조합입니다. 숫자보다 틀리는 방식이 문제의 성격을 알려줍니다.

Q. tau 를 0.53 으로 고른 근거가 뭔가요?

→ 검증셋에서 자동 처리 정확도 99% 를 목표로 잡고, 그 제약을 만족하는 것 중 커버리지가 가장 큰 값을 골랐습니다. 98% 나 98.5% 로 잡으면 tau 가 0.30 이 되면서 보류가 0장이 됩니다 — 제약이 작동하지 않는 겁니다. 그래서 제약이 실제로 걸리는 지점을 찾았습니다.

Q. test 를 한 번만 썼다는 걸 어떻게 보장하나요?

→ 모델 선정은 전부 검증셋 macro-F1 으로 했고, 해상도와 학습률 채택 판단도 검증셋 기준이었습니다. test 결과를 보고 되돌린 적이 없습니다. 실제로 학습률 $1e-4$ 채택 근거가 val 기준 $+0.0053$ 이었는데 test에서는 $+0.0001$ 이었습니다. 그래도 되돌리지 않고 val/test 불일치 사례로 기록했습니다.

Q. 효과가 없었으면 그 방법은 왜 시도했나요?

→ 검증셋에서는 개선이 있었기 때문입니다. 최적 계수가 0으로 나온 것도 검정을 돌린 뒤에 알았습니다. 시도하지 않았다면 '조정하면 더 좋아질 수도 있다'는 가정을 검증하지 못한 채 남겼을 겁니다.

Q. 나머지 세 검정은 왜 믿을 수 있나요?

→ 같은 절차로 검정했고 셋 다 귀무가설을 기각했습니다. 하나가 기각 실패였다는 사실이 오히려 검정 절차가 무조건 기각하도록 설계되지 않았다는 증거입니다.

Q. 실패 사례를 발표에 넣는 게 감점 요인 아닌가요?

→ 저희는 반대로 봅니다. test에서 임계값을 골랐다면 반드시 미세한 개선이 나왔을 것이고 그건 허구였을 겁니다. 검증셋에서 고르고 test에 한 번만 적용했기 때문에 확인할 수 있었습니다.

Q. 검정 네 개면 다중비교 보정이 필요하지 않나요?

→ 네 검정이 서로 다른 가설을 다루고 독립적인 질문이라 전체 오류율 보정 대상은 아니라고 판단했습니다. 다만 유리 색상 검정 안의 세 쌍 비교에는 Bonferroni 보정을 적용했습니다.

Q. '효과가 없다'와 '차이를 발견하지 못했다'는 다르지 않나요?

→ 맞습니다. 정확히는 후자입니다. 불일치 쌍이 0이라 검정 자체가 성립하지 않았고, 이는 효과가 없음을 증명한 것이 아니라 이 데이터에서 효과를 관측하지 못했다는 뜻입니다. 슬라이드에도 '효과가 없었다'가 아니라 '예측을 바꾸지 못했다'로 적었습니다.

Q. 실제 서비스에 쓸 수 있나요?

→ macro-F1 0.979 면 나쁘지 않지만 그대로 쓰기는 어렵습니다. 확신도 0.53 미만인 0.3% 를 사람이 확인하는 구조라면 98.8% 정확도로 운영 가능합니다. 다만 이 데이터셋은 제품 사진 위주라 실제 배출 현장의 더러워지고 구겨진 쓰레기에는 성능이 떨어질 가능성이 큼니다.

발표 직전 체크

- [] 앞 발표자(이현중)가 시행착오 슬라이드를 마치면 이어받는다
- [] 23번에서 정확도(0.9859)보다 macro-F1(0.9787)을 먼저 말한다
- [] 25·26·30번은 화면을 손으로 짚어가며 설명한다
- [] 27·29·30번에서 한 박자 쉰다 — 이 파트의 세 하이라이트
- [] 29번은 시간을 아끼지 않는다 (90초)
- [] 30번 기저귀 한 장을 반드시 짚는다
- [] 32번 마지막에 감사 인사로 발표 전체를 닫는다