

KDT-17 3rd Team Project

쓰레기 이미지 12 종 분류

데이터 품질에서 시작한 딥러닝 이미지 분류

3 조 (김이박)

팀장 이현중

팀원 김태경 · 박병찬

0 발표 구성

15 분 · 3 인 분담

1

김태경

데이터 이해

- 원본 데이터 현황과 클래스 불균형
- 이미지 품질 점검
- 정확도만 보면 안 되는 이유

5 분

2

이현중

정제와 모델링

- 중복 이미지 3 단계 탐지
- 라벨 오류 진단과 정정
- 모델 비교와 하이퍼파라미터

5 분

3

박병찬

평가와 해석

- 최종 성능과 클래스별 분석
- 오분류 패턴이 말하는 것
- 가설검정 · 운영 임계값

5 분

1

문제 정의

재활용 쓰레기 사진을 12 개 클래스로 자동 분류한다

데이터셋

- Kaggle mostafaabla/garbage-classification
- 원본 15,515 장 · 12 개 클래스
- battery, biological, brown-glass, cardboard,
- clothes, green-glass, metal, paper, plastic,
- shoes, trash, white-glass

왜 어려운가

- 클래스 불균형이 심하다 — 최다 clothes 5,325 장 ,
최소 brown-glass 607 장
- 유리 3 종은 형태가 같고 색만 다르다
- plastic / metal / paper 는 재질 경계가 사람에게도
모호하다
- 원본 데이터에 중복과 라벨 오류가 섞여 있다

2

전체 파이프라인

여덟 단계 중 앞의 네 단계가 데이터 품질에 대한 것이다



데이터 품질

모델링과 검증

전체 작업의 절반 이상이 데이터 품질에 쓰였다

데이터 품질 단계

원본을 그대로 학습에 넣지 않았다. 중복과 라벨 오류를 먼저 찾아내고, 그 근거를 문서로 남겼다.


모델링 · 검증 단계

정제된 데이터 위에서 모델을 비교하고, 성능 숫자가 믿을 만한지 통계로 확인했다.

3

데이터 현황

클래스별 이미지 수 — 최다와 최소가 8.77 배 차이



34.3%

clothes 한 클래스가
전체에서 차지하는 비중

8.77 배

최다 / 최소 클래스 비율

4

정확도만 보면 안 되는 이유

아무것도 학습하지 않은 모델을 실제로 측정했다

무지성 기준선

모든 입력을 clothes 라고만 답하는 모델

학습 없음 · 파라미터 0 개

정확도 0.3398

balanced accuracy 0.0833

macro-F1 0.0423

정확도는 34%
macro-F1 은 0.042

약 8 배 차이

정확도는 다수 클래스 하나만 잘 맞혀도 올라간다 .
macro-F1 은 12 개 클래스의 F1 을 동등 가중으로 평균하므로 ,
나머지 11 개를 전부 틀리면 즉시 무너진다 .

쓰레기 분류의 목적은 ' 많이 나오는 종류를 잘 맞히는 것 ' 이
아니라 ' 모든 종류를 고르게 맞히는 것 ' 이다 .

5

이미지 품질 점검

학습을 시작하기 전에 확인해야 할 것들

손상 파일

0 건

PIL verify 로 전수 검사.
학습 중 크래시 위험 없음

팔레트 (P) 모드

34 장

채널이 3 이 아니라 배치가 깨진다.
convert("RGB") 필수

해상도 산포

51 ~ 888px

종횡비도 제각각.
resize 필요 (128 / 224)

색상 정보

유리 3 종


형태가 같아 색이 유일한 단서.
증강에서 색을 건드리면 안 된다

6


유리 3 종의 색상 분석

형태가 같은 세 클래스를 가르는 단서는 색뿐이다

유리 3종의 색상 공간 분포



색 정보가 거의 없는 white-glass



클래스당 250 장 표본 · HSV 변환 후 채도 40 미만, 명도 30 미만 픽셀 제외 (배경 · 그림자 노이즈 차단)

→ 증강에서 hue = 0.0, saturation = 0.05 로 색을 거의 건드리지 않기로 결정

PART 2 · 이현중

폴더만 봐서는 알 수 없는 문제

같은 사진이 여러 장 들어 있고, 신발 사진이 clothes 폴더에 있었다

7

중복 이미지 탐지

1.2 억 쌍을 세 단계로 좁혀 들어간다

전체 이미지 쌍

약 1.2억 쌍

픽셀 단위 전수 비교는 불가능

dHash 후보

Hamming ≤ 5

구조가 비슷한 쌍만 후보로

픽셀 검증 통과

평균차 < 0.05

32×32 RGB 실제 값으로 재확인

최종 근접중복

42그룹

육안으로 오탐 7그룹 제외

MD5 만으로는 리사이즈·재저장된 같은 사진을 잡을 수 없다

18 그룹

완전 동일 (MD5)

3 그룹

라벨이 충돌

42 그룹

근접 중복

7 그룹

육안 오탐 제외

탐지 결과를 눈으로 확인한다

알고리즘이 찾은 것과 사람이 판단한 것

MD5로는 잡히지 않는 근접 중복

같은 그룹으로 묶인 세 장 · 파일 바이트는 서로 다르다




진짜 근접 중복

사람 눈에는 완전히 같은 사진인데 파일이 세 개다. 리사이즈나 재저장으로 바이트가 달라져 MD5로는 잡히지 않았다. 삭제하지 않고 같은 split에 묶었다.

알고리즘이 같다고 판정한 오탐

흰 배경 + 세로 물체 구도가 같을 뿐, 서로 다른 칫솔 제품이다



알고리즘의 오탐

dHash와 픽셀 검증을 모두 통과했지만 열어보니 서로 다른 칫솔 제품이었다. 흰 배경에 세로로 선 물체라는 제품 사진 구도가 같았을 뿐이다. 7그룹 30장을 제외했다.

라벨 오류 진단

모델을 데이터 검사 도구로 거꾸로 이용한다

착안점

모델이 " 확신 있게 틀린 " 예측은
둘 중 하나다

정말 헛갈리는 사진이거나, 원본 라벨이 잘못됐거나

왜 두 단계로 나뉘냐

train 데이터는 모델이 그 라벨 그대로 암기했기 때문에, 라벨이
틀려도 틀린 라벨을 그대로 재현해 " 틀림 " 으로 잡히지 않는다.
그래서 train 은 2-fold out-of-fold 로 " 안 본 상태 " 의 예측을 새로
만들어냈다.

진단 결과

1 단계 held-out

4,655 장

오분류 123 건 중 확신도 0.9 이상 59 건

2 단계 train OOF

10,838 장

오분류 382 건 중 확신도 0.9 이상 145 건

합계 204 건 전수 육안 확인

자동 추출은 후보 생성까지만. 라벨을 옮길지 뺄지는 전부 사람이
이미지를 직접 보고 판단했다.

9

실제로 어떤 사진이었나

모두 clothes 폴더에 들어 있던 파일이다

폴더가 알려주지 않는 라벨 오류

clothes 폴더에 들어 있던 신발 사진들 · 마지막 한 장은 반대 방향(반바지)

clothes3062 → shoes



clothes3330 → shoes



clothes5002 → shoes



clothes3545 → shoes



clothes2197 → shoes



shoes1826 → clothes



46 장

정정한 라벨 수

clothes → shoes 43

shoes → clothes 1

색상 · 재질 2

왜 중요한가

모델이 clothes 를 shoes 로 틀렸을 때, 그건 모델의 실수가 아니라 정답이 잘못돼 있던 것이다.

모델을 개선해도 줄지 않던 이유다.

11 정제 결과

파일을 옮기거나 지우지 않고 manifest 한 장으로 관리했다

15,515

원본



- 31

제외



15,484

최종

46 장

라벨 정정

완전 동일 중복 여분

16 장

그룹당 1 장만 유지

라벨이 충돌한 중복

6 장

같은 사진에 다른 라벨 — 양쪽 모두 제외

애매한 경계 사례

3 장

사람이 봐도 판단이 갈림

사진이 아닌 이미지

6 장

클립아트 · 목업 템플릿 · 스케치

라벨 정정

46 장

clothes → shoes 43, 그 외 3

근접 중복 그룹


25 그룹

삭제하지 않고 같은 split 에 배치

데이터 분할

같은 사진이 train 과 test 로 갈라지면 시험 문제를 미리 본 셈이다

단순 계층 분할 — 같은 사진이 갈라진다



13그룹 26장이 양쪽에 걸침 → test 점수 부풀려짐

그룹 인지 분할 — 통째로 한쪽에



같은 그룹은 항상 같은 쪽 → 갈라진 그룹 0개

MD5 는 근접 중복을 못 잡는다

바이트가 1 비트만 달라도 다른 파일로 본다 . 리사이즈하거나 다시 저장하면 해시가 완전히 달라진다 .

최종 분할 70 / 15 / 15

10,832

train

2,318


val

2,334

test

모델 비교

밑바닥 학습 vs 전이학습 — 검증셋 macro-F1 기준



전이학습의 효과

+0.32

ImageNet 128 만 장에서 배운 특징이
쓰레기 사진에도 그대로 통한다

학습률 비교

5e-5	0.9731
1e-4	0.9600
3e-4	0.9658

후보 3 개를 전부 끝까지 학습해 비교

시행착오에서 배운 것

짧은 스윙으로 고른 학습률이 최종 학습에서는 최선이 아니었다

처음 방법

4 에폭 미니스윙 → 승자만 완전 학습

5e-5	0.9538
1e-4	0.9629 ← 스윙 승자
3e-4	0.9479

그런데 1e-4 로 최종 학습을 돌렸더니 조기 종료가 6 에폭째 발동해 0.9652 에 그쳤다. 스케줄러가 개입할 기회조차 없었다.

고친 방법

후보 3 개를 전부 최종 설정으로 완전 학습

5e-5	0.9731	15/15 · 조기종료 없음
1e-4	0.9600	9/15
3e-4	0.9658	13/15

스케줄러와 조기 종료가 있는 설정에서는, 그 설정을 빼고 진행한 짧은 스윙의 순위가 최종 결과의 순위를 보장하지 못한다.

PART 3 · 박병찬

숫자가 진짜인지 확인하는 단계

test 는 여기서 단 한 번만 사용한다



15

최종 성능

EfficientNetV2-S (unfreeze, lr 5e-5) · test 2,334 장

0.9773

accuracy

0.9671

macro-F1


0.9668

macro-recall

0.9995

macro-AUC

클래스별 F1



가장 약한 세 클래스


plastic 0.911
metal 0.933 (정밀도 0.903)
cardboard 0.958

재질 경계가 모호한 클래스들이다.
정제로 해결되는 문제가 아니다.

무엇을 무엇으로 틀렸나

2,334 장 중 53 건 · 대각선이 정답, 나머지가 오분류

test 혼동행렬 · 2,334장 중 오분류 53건



읽는 법

- 행 = 실제 라벨
- 열 = 모델 예측
- 진할수록 그 행에서 차지하는 비중이 크다
- 대각선 밖 숫자가 오분류

눈에 띄는 것

대각선이 압도적으로 진하다.
clothes 793 장 중 791 장 정답.

남은 오분류는 재질계에 몰려 있다.
plastic 행이 가장 넓게 흩어져 있고,
cardboard → paper 5 건이 최다다.

오분류 패턴이 말하는 것

정제 효과는 정확도 숫자가 아니라 틀리는 방식에서 드러났다

정제 전

clothes → shoes 가 실험 내내 1 위

20 건대를 계속 유지했다. 모델을 아무리 개선해도 줄지 않았는데, 원인이 모델이 아니라 원본 라벨이었기 때문이다.

정제 후 상위 오분류

cardboard → paper	5 건
plastic → metal	5 건
plastic → paper	4 건
white-glass → plastic	4 건
clothes → shoes	2 건

EDA 가 실패 지점을 미리 알려줬다

평균 채도 / 유효 색상 픽셀 비율


brown-glass	60.85	0.37
green-glass	63.68	0.40
white-glass	19.78	0.14

white-glass 는 채도가 다른 유리의 3 분의 1 이다. 투명 유리라 색 정보가 거의 없어 질감과 반사에만 의존하게 되고, 그것이 금속 광택과 겹친다.

모델은 얼마나 확신하는가

이 분포가 운영 임계값을 정하는 근거가 된다


모델은 대부분 확신하고, 확신할 때는 맞는다



정답일 때와 오답일 때가 갈린다

정답 2,281 장은 확신도 1.0 근처에 몰려 있고, 오답 53 건은 넓게 퍼져 있다.

얼마를 사람이 확인할 것인가



운영으로 옮기면

1.6%(38 장) 만 사람이 확인하면 나머지는 98.4% 정확도로 자동 분류된다.

이 어 지 는 내 용

가설검정과 운영 임계값

1 평가지표 선정의 통계적 근거

부트스트랩 95% 신뢰구간으로 accuracy 와 macro-F1 격차의 유의성 검정

2 가설검정 4 종

순열검정 · Kruskal-Wallis + Mann-Whitney · 부트스트랩 CI · McNemar

3 임계값에 따른 지표 변화

One-vs-Rest 스윕 · 클래스별 가중 argmax · 확신도 기반 판단 보류

4 운영 관점 결론

몇 퍼센트를 사람이 확인하면 나머지를 몇 퍼센트 정확도로 자동 처리할 수 있는가