

발표 학습용 자료

슬라이드 26장 · 대본 · 예상 질문

3조 (김이박) — 이현중 · 김태경 · 박병찬

쓰는 법

- 슬라이드 이미지와 대사가 한 화면에 붙어 있습니다. 순서대로 넘기며 연습하세요.
- **짧은 문장은 반드시 말해야 하는 핵심**입니다. 나머지는 상황에 따라 줄이세요.
- 슬라이드마다 목표 시간이 적혀 있습니다. **합계 18분**입니다.
- 대본을 외우지 마시고, **각 슬라이드에서 전달할 한 문장만** 기억하세요.
- 마지막에 예상 질문과 답변, 발표 전 체크리스트가 있습니다.

파트 분담

도입 (공통)	슬라이드 1-4	1분 20초
김태경	슬라이드 5-9	5분
이현중	슬라이드 10-18	6분
박병찬	슬라이드 19-26	6분

슬라이드 1 · 20초

표지




“안녕하세요. 3조 발표를 시작하겠습니다. 저희 주제는 재활용 쓰레기 사진을 12개 종류로 자동 분류하는 것입니다.”

“부제를 '데이터 품질에서 시작한 딥러닝 이미지 분류'라고 붙였는데요, 저희 프로젝트에서 가장 많은 시간이 들어간 곳이 모델이 아니라 데이터였기 때문입니다.”

슬라이드 2 · 25초

발표 구성



“발표는 세 파트로 나눠서 진행합니다.”

“먼저 김태경 팀원이 데이터를 어떻게 이해했는지, 그 과정에서 어떤 문제를 발견했는지 말씀드립니다.

다음으로 제가(이현중이) 그 문제를 어떻게 정제하고 모델을 만들었는지 설명하고요. 마지막으로 박병찬 팀원이 결과를 평가하고 해석합니다.”

“한 가지 미리 말씀드리면, 저희는 주요 주장마다 통계 검정을 붙였습니다. 네 개인데, 따로 몰아두지 않고 각 주장이 나오는 자리에서 바로 검증합니다.”

(발표자 교대 시점을 미리 알려두면 청중이 따라오기 쉽습니다.)

슬라이드 3 · 20초

문제 정의

1 문제 정의

재활용 쓰레기 사진을 12 개 클래스로 자동 분류한다

데이터셋

- Kaggle mostafaabla/garbage-classification
- 원본 15,515 장 · 12 개 클래스
- battery, biological, brown-glass, cardboard,
- clothes, green-glass, metal, paper, plastic,
- shoes, trash, white-glass

왜 어려운가

- 클래스 불균형이 심하다 — 최다 clothes 5,325 장 , 최소 brown-glass 607 장
- 유리 3 종은 형태가 같고 색만 다르다
- plastic / metal / paper 는 재질 경계가 사람에게도 모호하다
- 원본 데이터에 중복과 라벨 오류가 섞여 있다

네 가지 어려움 중 마지막 항목이 이 발표의 축이다 . 폴더 구조만 봐서는 알 수 없는 문제를 먼저 찾아냈고 , 그 과정을 파트 2 에서 다룬다 .

“ 데이터셋은 Kaggle의 garbage-classification입니다. 원본 15,515장에 12개 클래스입니다. ”

“ 어려운 점이 네 가지 있었습니다. 클래스 불균형이 심하고, 유리 3종은 형태가 같아 색만 다르고, 플라스틱·금속·종이는 재질 경계가 사람에게도 모호합니다. ”

“ 그리고 마지막이 저희가 발표에서 가장 강조하고 싶은 부분인데, 원본 데이터에 중복과 라벨 오류가 섞여 있었습니다. ”

슬라이드 4 · 15초

전체 파이프라인



“전체 흐름을 한 장으로 보시면 이렇습니다. 데이터 이해, 정제, 모델링, 평가 네 단계입니다.”


“앞의 절반이 데이터 품질에 대한 것입니다. 원본을 그대로 학습에 넣지 않았습니다.”

“그럼 김태경 팀원이 첫 파트를 시작하겠습니다.”

PART 1 · 김태경 — 데이터 이해 · 5분

슬라이드 5 · 50초

데이터 현황



“클래스별 이미지 수입니다. 한눈에 보이시는 것처럼 clothes 하나가 5,325장으로 압도적입니다.”

“전체의 34.3%, 3분의 1이 넘습니다. 반면 가장 적은 brown-glass는 607장입니다. 최다와 최소가 8.77배 차이납니다.”

“이 불균형이 저희 프로젝트 내내 따라다니는 조건이 됩니다. 다음 장에서 왜 그런지 보여드리겠습니다.”

슬라이드 6 · 70초

정확도의 함정

4
정확도만 보면 안 되는 이유

아무것도 학습하지 않은 모델을 실제로 측정했다

무지성 기준선

모든 입력을 **clothes** 라고만 답하는 모델

학습 없음 · 파라미터 0 개

정확도 **0.3398**

balanced accuracy **0.0833**

macro-F1 **0.0423**

정확도는 34%
macro-F1 은 0.042

약 8 배 차이

정확도는 다수 클래스 하나만 잘 맞혀도 올라간다 .
macro-F1 은 12 개 클래스의 F1 을 동등 가중으로 평균하므로 ,
나머지 11 개를 전부 틀리면 즉시 무너진다 .

쓰레기 분류의 목적은 ' 많이 나오는 종류를 잘 맞히는 것 ' 이
아니라 ' 모든 종류를 고르게 맞히는 것 ' 이다 .

주 평가지표로 macro-F1 을 채택하고 accuracy · weighted-F1 · macro-AUC 는 참고로 병기한다 . 유비가 아니라 우리 데이터에서 직접 측정한 반례다 .

“ 불균형이 왜 문제인지 말로 설명하는 대신 직접 측정해봤습니다. ”

“ **"모든 입력을 clothes라고만 답하는 모델"**을 만들었습니다. 학습을 전혀 하지 않았고, 파라미터가 0개입니다. 그냥 무조건 clothes라고 찍는 겁니다. ”

“ 이 모델의 정확도가 얼마일까요. **34%입니다.** 아무것도 배우지 않았는데 3분의 1을 맞힙니다. ”

“ 그런데 macro-F1은 0.042입니다. **약 8배 차이납니다.** ”

“ 이유는 간단합니다. 정확도는 다수 클래스 하나만 잘 맞혀도 올라갑니다. 반면 macro-F1은 12개 클래스의 F1을 동등하게 평균하기 때문에, 나머지 11개를 전부 틀리면 즉시 무너집니다. ”

“ **쓰레기 분류의 목적은 많이 나오는 종류를 잘 맞히는 게 아니라 모든 종류를 고르게 맞히는 것입니다.** 그래서 저희는 macro-F1을 주 평가지표로 정했습니다. 정확도는 참고로만 함께 기록합니다. ”

여기서 한 박자 쉬세요. 이 슬라이드가 발표 전체에서 가장 중요한 논리입니다.

슬라이드 7 · 40초

이미지 품질 점검

5
이미지 품질 점검

학습을 시작하기 전에 확인해야 할 것들

손상 파일

0 건

PIL verify 로 전수 검사했다 .

학습 중 크래시 위험은 없다

팔레트 (P) 모드

34 장

채널이 3 이 아니라 배치가 깨진다 .

convert("RGB") 가 필수다

해상도 산포

51 ~ 888px

종횡비도 제각각이다 .

resize 가 필요하다 (128 / 224)

색상 정보

유리 3 종

형태가 같아 색이 유일한 단서다 .

증강에서 색을 건드리면 안 된다

네 항목 모두 감이 아니라 세어본 값이다 . P 모드 34 장이 실제로 있었기 때문에 convert("RGB") 는 관행이 아니라 근거 있는 처리다 .

“ 학습을 시작하기 전에 네 가지를 확인했습니다. ”


“ 손상 파일은 0건이었습니다. 학습 도중 크래시가 날 위험은 없었습니다. ”

“ **팔레트 모드 파일이 34장 있었습니다.** 이건 채널이 3개가 아니라서 그대로 텐서로 만들면 배치가 깨집니다. 그래서 convert("RGB")를 넣었는데, 이건 관행적인 방어 코드가 아니라 **실제로 세어본 근거가 있는 처리**입니다. ”

“ 해상도는 51픽셀부터 888픽셀까지 제각각이라 resize가 필요했고, 유리 3종은 색이 유일한 단서라 증강에서 주의가 필요했습니다. 마지막 항목은 다음 장에서 자세히 보겠습니다. ”

슬라이드 8 · 70초

유리 3종 색상 분석



“ brown-glass, green-glass, white-glass 세 클래스는 모양이 거의 같습니다. 셋 다 병입니다. 사람이 구분하는 단서는 사실상 **색 하나**뿐입니다. ”

“ 여기서 판단이 갈립니다. 보통 이미지 증강 레시퍼는 ColorJitter로 색을 혼듭니다. 과적합을 막는 표준 기법이죠. 그런데 **색이 곧 정답 신호인 클래스가 있다면, 이 증강은 정답을 지우는 노이즈가 됩니다.** ”

“ 그래서 감으로 정하지 않고 측정했습니다. 클래스당 250장씩 뽑아 HSV로 변환하고, 배경과 그림자 노이즈를 걸러낸 뒤 색상 분포를 봤습니다. ”

“ 왼쪽 산점도를 보시면 white-glass가 왼쪽 아래에 몰려 있습니다. **채도가 19.78로 다른 유리의 3분의 1입니다.** 오른쪽 막대를 보시면 유효 색상 픽셀 비율도 0.14로 절반 이하입니다. ”


“ 투명 유리라 색 정보가 거의 없다는 뜻입니다. ”

“ **결론은 증강에서 hue를 0으로, saturation을 0.05로 최소화했습니다.** 밝기와 대비만 혼듭니다. 조명 차이는 실제로 존재하는 변동이지만, 색상 자체는 라벨 정보이기 때문입니다. ”

“ 참고로 이 white-glass의 색 정보 부족은 나중에 모델이 어디서 틀리는지와 정확히 연결됩니다. 박병찬 팀원 파트에서 다시 나올 겁니다. ”

슬라이드 9 · 60초

검정 1 색 차이는 우연이 아닌가



“ 그런데 방금 보신 검침 계수는 기술통계일 뿐입니다. "우연히 이만큼 차이가 났을 가능성"은 말해주지 않습니다. ”

“ 그래서 검정을 붙였습니다. 귀무가설은 "세 클래스의 색상 분포가 같다", 대립가설은 "다르다"입니다. ”

“ 방법은 순열검정입니다. 라벨을 무작위로 섞어서 차이가 없는 세상을 5,000번 만듭니다. 그리고 그 세상에서 우리가 관측한 만큼의 분리가 나올 확률을 셉니다. 분포 가정이 필요 없어서 색상값처럼 정규분포와 거리가 먼 데이터에 적합합니다. ”

“ 결과가 그래프에 있습니다. 오른쪽 연한 덩어리가 라벨을 섞었을 때의 분포이고, 왼쪽 빨간 선이 관측값입니다. ”


“ 두 개가 완전히 떨어져 있습니다. 표준편차로 16배 거리입니다. 5,000번 중에 관측값만큼 낮게 나온 경우가 사실상 없었다는 뜻이고, p값은 0.0002입니다. ”

“ 귀무가설을 기각합니다. 색은 유리 3종을 가르는 유효한 신호이고, 따라서 증강에서 색을 흔들지 않기로 한 결정에 통계적 근거가 생겼습니다. ”

(그래프의 두 덩어리가 떨어져 있다는 것만 짚어도 충분합니다. p값을 길게 설명할 필요 없습니다.)

슬라이드 10 · 10초

전환




“ 지금까지는 폴더 구조가 알려주는 것들이었습니다. 그런데 폴더만 봐서는 알 수 없는 문제가 있었습니다. ”

“ 이현중 팀장이 이어서 설명하겠습니다. ”

PART 2 · 이현중 — 정제와 모델링 · 6분

슬라이드 11 · 75초

중복 이미지 탐지



“같은 사진이 데이터셋에 여러 장 들어 있었습니다.”

“문제는 어떻게 찾느냐입니다. 15,515장을 전부 픽셀 단위로 비교하면 약 1.2억 쌍인데, 현실적으로 불가능합니다.”

“그래서 세 단계로 좁혔습니다.”

“첫째, **MD5 해시**로 바이트가 완전히 같은 파일을 찾습니다. 이건 $O(n)$ 에 끝납니다.”

“둘째, 여기서 끝나면 안 됩니다. **MD5는 바이트가 1비트만 달라도 다른 파일로 봅니다.** 같은 사진을 리사이즈하거나 다시 저장하면 해시가 완전히 달라지죠. 그래서 dHash를 썼습니다. 인접 픽셀의 밝기가 오르는지 내리는지, 즉 구조만 기록하는 해시입니다. 256비트 중 5비트 이내로 차이나는 쌍만 후보로 올립니다.”

“셋째, 구조가 비슷하다고 같은 사진은 아니니 **실제 픽셀 값으로 한 번 더 검증**합니다.”

“마지막으로 Union-Find로 연결된 쌍을 하나의 그룹으로 묶었습니다.”

“결과는 아래 보시는 대로입니다. 완전 동일 18그룹, 클래스가 서로 다른 충돌이 3그룹, 근접 중복이 42그룹입니다.”

“그리고 여기서 중요한 게 **오탐 7그룹**입니다. 알고리즘 두 단계를 다 통과했는데 열어보니 서로 다른 칫솔 제품 사진이었습니다. 흰 배경에 세로로 선 물체라는 제품 사진 특유의 구도가 같았던 겁니다. **알고리즘은 후보만 좁히고, 최종 판단은 사람이 직접 이미지를 열어서 했습니다.**”

슬라이드 12 · 40초

탐지 결과를 눈으로 확인

10
탐지 결과를 눈으로 확인한다

알고리즘이 찾은 것과 사람이 판단한 것

MD5로는 잡히지 않는 근접 중복

같은 그룹으로 묶인 세 장 · 파일 바이트는 서로 다르다

green-glass2

green-glass292

green-glass443

알고리즘이 같다고 판정한 오탐

흰 배경 + 세로 물체 구도가 같을 뿐, 서로 다른 칫솔 제품이다

trash357

trash384

trash413

진짜 근접 중복

사람 눈에는 완전히 같은 사진인데 파일이 세 개다. 리사이즈나 재저장으로 바이트가 달라져 MD5로는 잡히지 않았다. 삭제하지 않고 같은 split에 묶었다.

알고리즘의 오탐

dHash와 픽셀 검증을 모두 통과했지만 열어보니 서로 다른 칫솔 제품이었다. 흰 배경에 세로로 선 물체라는 제품 사진 구도가 같았을 뿐이다. 7그룹 30장을 제외했다.

“실제로 어떻게 생긴 사진인지 보시겠습니다.”

“**왼쪽이 진짜 근접 중복입니다.** 초록 병 사진 세 장인데, 보시다시피 사람 눈에는 완전히 같은 사진입니다. 그런데 파일이 세 개고 바이트가 서로 다릅니다. 리사이즈나 재저장 과정에서 달라진 거죠. **MD5로는 이걸 절대 못 잡습니다.**”

“이런 사진이 train과 test로 갈라지면 안 되니까, 삭제하지 않고 같은 split에 묶었습니다.”

“**오른쪽이 오탐입니다.** 알고리즘 두 단계를 다 통과했는데 열어보니 서로 다른 칫솔 제품입니다. 흰 배경에 세로로 선 물체라는 제품 사진 구도가 같았을 뿐입니다.”

“**7그룹 30장을 사람이 직접 보고 제외했습니다.** 알고리즘만 믿었으면 엄청난 데이터를 잃었을 겁니다.”

(왼쪽 오른쪽을 손으로 가리키며 대비시키면 효과적입니다.)

슬라이드 13 · 70초

라벨 오류 진단

12

라벨 오류 진단

모델을 데이터 검사 도구로 거꾸로 이용한다

착안점

모델이 " 확신 있게 틀린 " 예측은 둘 중 하나다

정말 헛갈리는 사진이거나, 원본 라벨이 잘못됐거나

왜 두 단계로 나뉘냐

train 데이터는 모델이 그 라벨 그대로 암기했기 때문에, 라벨이 틀려도 틀린 라벨을 그대로 재현해 " 틀림 " 으로 잡히지 않는다 .

그래서 train 은 2-fold out-of-fold 로 " 안 본 상태 " 의 예측을 새로 만들어냈다 .

진단 결과

1 단계 held-out	4,655 장	오분류 123 건	확신도 0.9 이상 59 건
2 단계 train OOF	10,838 장	오분류 382 건	확신도 0.9 이상 145 건

합계 204 건 전수 육안 확인

자동 추출은 후보 생성까지만, 라벨을 옮길지 뺄지는 전부 사람이 이미지를 직접 보고 판단했다.

“ 중복보다 더 어려운 게 라벨 오류였습니다. 신발 사진이 clothes 폴더에 들어가 있는 경우죠. ”

“ 착안점은 이겁니다. **모델이 확신하며 틀린 예측은 둘 중 하나입니다.** 정말 헛갈리는 사진이거나, 원본 라벨이 잘못됐거나. ”

“ 이 둘을 구분하려고 확신도 0.9 이상으로 틀린 예측을 전부 뽑아서 사람이 직접 봤습니다. **모델을 고치는 게 아니라, 데이터를 진단하는 도구로 모델을 거꾸로 이용한 겁니다.** ”

“ 그런데 여기에 함정이 있습니다. **train 데이터는 모델이 그 라벨을 그대로 암기했기 때문에, 라벨이 틀려도 틀린 라벨을 그대로 재현해서 "틀림"으로 안 잡힙니다.** ”

“ 그래서 두 단계로 나뉘었습니다. held-out은 최종 모델을 그대로 썼고, train은 절반씩 나눠 서로 반대쪽으로 학습한 두 모델로 교차 평가했습니다. 이렇게 하면 "안 본 상태"의 정직한 예측을 얻습니다. ”

“ 결과는 held-out 59건, train 145건, **합계 204건을 전수 육안 확인했습니다.** ”

슬라이드 14 · 40초

실제로 어떤 사진이었나

13 실제로 어떤 사진이었나

모두 clothes 폴더에 들어 있던 파일이다

폴더가 알려주지 않는 라벨 오류

clothes 폴더에 들어 있던 신발 사진들 - 마지막 한 장은 반대 방향(반바지)

clothes3062 → shoes



clothes3330 → shoes



clothes5002 → shoes



clothes3545 → shoes



clothes2197 → shoes



shoes1826 → clothes



46 장

정정한 라벨 수

clothes → shoes 43

shoes → clothes 1

색상 · 재질 2

왜 중요한가

모델이 clothes 를 shoes 로 틀렸을 때 , 그건 모델의 실수가 아니라 정답이 잘못돼 있던 것이다 .

모델을 개선해도 좋지 않던 이유다 .

“ 이게 라벨 오류의 실물입니다. 여섯 장 전부 clothes 폴더에 들어 있던 파일입니다. ”

“ 구두, 운동화, 샌들, 장화... 누가 봐도 신발입니다. 오른쪽 아래 한 장만 반대 방향인데, shoes 폴더에 들어 있던 반바지 사진입니다. ”


“ 이런 걸 46장 찾아서 정정했습니다. ”

“ 왜 중요하냐면, 모델이 clothes를 shoes로 틀렸을 때 그건 모델의 실수가 아니라 정답이 잘못돼 있던 것이기 때문입니다. 모델을 아무리 개선해도 이 오분류가 줄지 않던 이유가 여기 있었습니다. ”

(사진을 먼저 3초쯤 보여준 뒤 말을 시작하세요.)

슬라이드 15 · 45초

정제 결과



“ 정제 결과입니다. 15,515장에서 31장을 빼서 최종 15,484장, 그리고 46장의 라벨을 정정했습니다. ”

“ 내역은 아래 표에 있습니다. 완전 동일 중복 여분 16장, 라벨이 충돌한 중복 6장, 애매한 경계 3장, 사진이 아닌 이미지 6장입니다. ”


“ 라벨 정정 46장은 대부분 clothes에서 shoes로 옮긴 것입니다. ”

“ 한 가지 원칙이 있는데, 파일을 옮기거나 지우지 않았습니다. manifest CSV 한 장으로 관리했습니다. 어떤 파일을 왜 뺐는지 이유가 남고, 잘못했으면 되돌릴 수 있습니다. ”

“ 그리고 근접 중복 25그룹은 삭제하지 않았습니다. 왜 그런지는 다음 장에서 말씀드립니다. ”

슬라이드 16 · 60초

데이터 분할



“ 근접 중복을 왜 안 지웠냐면, 지우는 것보다 **분할을 제대로 하는 게 중요하기** 때문입니다. ”

“ 왼쪽 그림을 보시면, 흔히 쓰는 단순 계층 분할입니다. 클래스 비율만 맞추고 무작위로 나누죠. 이러면 **같은 사진이 train과 test로 갈라집니다**. 저희 데이터에서는 13그룹 26장이 그렇게 갈라졌습니다. ”


“ 이게 왜 문제냐면, **모델이 시험 문제를 미리 본 셈**이 되기 때문입니다. test에 있는 그 사진을 train에서 이미 봤으니 거의 확실히 맞습니다. test 점수가 부풀려지는 거죠. ”

“ 오른쪽이 저희가 쓴 방식입니다. Union-Find로 묶은 그룹은 통째로 한쪽에만 들어가게 했습니다. **갈라진 그룹 0개**입니다. ”

“ 최종 분할은 70 대 15 대 15로, train 10,832장, val 2,318장, test 2,334장입니다. **test는 마지막에 딱 한 번만 씁니다.** ”

슬라이드 17 · 50초

모델 비교



“ 이제 모델입니다. 세 가지를 비교했습니다. ”

“ 먼저 직접 만든 CNN입니다. 사전학습 없이 밀바닥부터 배웁니다. val macro-F1이 0.652 나왔습니다. ”

“ 다음은 EfficientNetV2-S에 ImageNet 사전학습 가중치를 가져오되 백본은 동결하고 마지막 층만 학습했습니다. 0.809입니다. ”

“ 마지막으로 동결을 풀고 전체를 미세조정하면서 입력을 224px로 올렸더니 **0.984까지 올라갔습니다.** ”

“ **밀바닥 학습 대비 0.33 차이입니다.** ImageNet 128만 장에서 배운 시각적 특징이 쓰레기 사진에도 그대로 통한다는 뜻입니다. ”

“ 오른쪽 아래는 224px에서의 학습률 비교인데 1e-4가 가장 좋았습니다. 그런데 이 값을 고르는 과정에서 배운 게 있습니다. ”

슬라이드 18 · 45초

시행착오

17 시행착오에서 배운 것

128px 에서 최적이던 학습률이 224px 에서도 최적은 아니었다

처음 방법

128px 기준으로 고른 학습률

5e-5	0.9731 ← 128px 최적
1e-4	0.9600
3e-4	0.9658

그런데 입력을 224px 로 올린 뒤 같은 학습률을 그대로 쓰자 val macro-F1 이 0.9787 에 그쳤다. 128px 에서 최적이던 값이 224px 에서도 최적은 아니었다.

고친 방법

224px 에서 학습률을 다시 골랐다

1e-4	0.9840	채택
5e-5	0.9787	128px 최적값
3e-4	0.9738	

조건이 바뀌면 하이퍼파라미터도 다시 골라야 한다. 해상도를 올렸으면 학습률도 다시 탐색해야 한다는 뜻이다.

“ 처음에는 128px 기준으로 학습률을 골랐습니다. 후보 세 개를 전부 끝까지 학습시켜 비교했고 **5e-5가 0.9731로 승자**였습니다. ”

“ 그다음 입력 해상도를 128에서 224로 올렸습니다. 재질이 비슷한 클래스가 계속 헷갈렸는데, **질감 정보가 저해상도에서 날아간 게 아닐까** 싶었기 때문입니다. ”

“ 실제로 크게 올랐습니다. plastic이 0.911에서 0.958로, metal이 0.933에서 0.962로요. ”

“ 그런데 여기서 실수할 뻔했습니다. 해상도만 바꾸고 학습률은 128px에서 고른 5e-5를 그대로 썼는데, val macro-F1이 0.9787에 그쳤습니다. ”

“ 224px에서 학습률을 다시 탐색해보니 **1e-4가 0.9840으로 더 좋았습니다.** ”

“ 교훈은 이겁니다. 조건이 바뀌면 하이퍼파라미터도 다시 골라야 합니다. 128px에서 최적이던 값이 224px에서도 최적이라는 보장은 없습니다. ”

“ 그럼 박병찬 팀원이 평가 파트를 이어가겠습니다. ”

PART 3 · 박병찬 — 평가와 해석 · 6분

슬라이드 19 · 10초

전환




“ 지금까지 모델을 만들었으니, 이제 그 숫자가 진짜인지 확인할 차례입니다. ”

“ test는 여기서 단 한 번만 사용합니다. ”

슬라이드 20 · 55초

최종 성능



“ 최종 모델은 EfficientNetV2-S 미세조정에 입력 224px, 학습률 1e-4입니다. test 2,334장에 적용한 결과입니다. ”

“ 정확도 0.9859, 주 지표인 macro-F1은 0.9787, macro-AUC는 0.9998입니다. ”


“ 아래는 클래스별 F1을 낮은 순으로 정렬한 것입니다. 왼쪽 두 개가 가장 약합니다. ”

“ plastic이 0.932로 최저이고, white-glass가 0.948입니다. metal은 재현율이 1.000인데 정밀도가 0.943입니다 — 애매하면 metal이라고 답하는 경향이 남아 있습니다. ”

“ 이 클래스들은 재질 경계가 모호합니다. 정제로 해결되는 문제가 아닙니다. 페트병과 캔, 종이팩과 판지는 사람이 봐도 헷갈립니다. ”

슬라이드 21 · 55초

검정 2 두 지표의 격차는 유의한가



“ 정확도 0.9859, macro-F1 0.9787. 차이가 0.7%p 정도입니다. 이게 진짜 차이인지, 아니면 test 2,334장을 어쩌다 그렇게 뽑아서 생긴 우연인지 확인해야 합니다. ”

“ 귀무가설은 "두 지표의 차이가 0이다"입니다. ”

“ 방법은 부트스트랩입니다. test에서 복원추출로 같은 크기의 표본을 2,000번 만들고, 매번 두 지표의 차이를 계산합니다. 그 차이 분포의 95% 신뢰구간이 0을 포함하지 않으면 귀무가설을 기각합니다. ”

“ 왼쪽 그래프를 보시면 두 지표의 분포가 거의 겹치지 않습니다. 오른쪽이 그 차이의 분포인데, 신뢰구간이 0.0046에서 0.0102입니다. ”

“ 0을 포함하지 않습니다. 귀무가설을 기각합니다. ”

“ 2,000번 재표본을 뽑았는데 두 지표가 뒤집힌 경우가 한 번도 없었다는 뜻입니다. 앞에서 김태경 팀원이 말한 "정확도가 소수 클래스 실패를 가린다"가 최종 모델에서도 통계적으로 확인된 겁니다. ”

슬라이드 22 · 55초

혼동행렬



“ 어떤 클래스를 어떤 클래스로 틀렸는지 혼동행렬로 보겠습니다. 행이 실제 라벨, 열이 모델 예측입니다.”

“ 먼저 대각선이 압도적으로 진합니다. clothes는 793장을 전부 맞혔습니다.”

“ 2,334장 중 오분류가 33건뿐입니다.”

“ 그런데 그 33건이 어디에 몰려 있는지가 중요합니다. white-glass와 plastic 사이가 9건으로 최다입니다. 투명 유리병과 투명 페트병이죠.”

“ 나머지도 대부분 metal 관련입니다. cardboard에서 metal로 2건, white-glass에서 metal로 2건입니다.”

“ 즉 남은 오류는 재질계에 몰려 있습니다. 이건 데이터 문제가 아니라 문제 자체의 난이도입니다.”

슬라이드 23 · 60초

오분류 패턴

22 오분류 패턴이 말하는 것

정제 효과는 정확도 숫자가 아니라 틀리는 방식에서 드러났다

정제 전

clothes → shoes 가 실험 내내 1 위

20 건대를 계속 유지했다. 모델을 아무리 개선해도 줄지 않았는데, 원인이 모델이 아니라 원본 라벨이었기 때문이다.

정제 후 상위 오분류

white-glass → plastic	5 건
plastic → white-glass	4 건
cardboard → metal	2 건
white-glass → metal	2 건
clothes → shoes	0 건

EDA 단계에서 이미 확인한 위험이었다

평균 채도 / 유효 색상 픽셀 비율

brown-glass	60.85	0.37
green-glass	63.68	0.40
white-glass	19.78	0.14

EDA 에서 white-glass 의 채도가 다른 유리의 3 분의 1 이라는 것을 확인했다. 색 정보가 없으면 질감과 반사에 의존하게 되고 금속 광택과 겹칠 수 있다 — 이 위험을 미리 파악한 상태에서 모델링에 들어갔고, 실제 오분류가 그 예상과 일치했다.

“ 그런데 여기서 흥미로운 게 있습니다. 정제 효과가 정확도 숫자가 아니라 틀리는 방식에서 드러났습니다. ”

“ 정제 전에는 clothes를 shoes로 틀리는 게 실험 내내 1위였습니다. 20건대를 계속 유지했습니다. 모델을 아무리 개선해도 줄지 않았는데, 원인이 모델이 아니라 원본 라벨이었기 때문입니다. ”

“ 정제와 해상도 개선을 거친 지금은 top-10에서 아예 사라졌습니다. 상위 오분류가 전부 재질·색상 혼동으로 바뀌었습니다. ”

“ 그리고 오른쪽이 이 발표에서 저희가 가장 하고 싶은 이야기입니다. ”

“ 이 오분류는 EDA 단계에서 이미 확인해둔 위험이었습니다. ”


“ 앞서 김태경 팀원이 보여드린 표를 다시 보시면, white-glass의 채도가 19.78로 다른 유리의 3분의 1이었죠. 유효 색상 픽셀 비율도 0.14로 절반 이하였고요. ”

“ 색 정보가 없으면 모델은 질감과 반사에만 의존하게 되고, 그것이 금속 광택과 겹칠 수 있습니다. 저희는 이 위험을 미리 파악한 상태에서 모델링에 들어갔고, 실제 오분류가 그 예상과 일치했습니다. ”

“ EDA를 형식적으로 넘기지 않고 정량적으로 확인해둔 것이 결과 해석에 그대로 쓰인 셈입니다. ”

슬라이드 24 · 50초

확신도 분포



“ 마지막으로 모델이 얼마나 확신하는지 봤습니다. ”

“ 왼쪽 히스토그램에서 초록이 정답, 주황이 오답입니다. 정답 2,301장은 확신도 1.0 근처에 몰려 있고, 오답 33건은 넓게 퍼져 있습니다. ”

“ 두 분포가 갈린다는 건 중요합니다. 확신도만 보고도 "이건 사람이 다시 봐야 한다"를 걸러낼 수 있다는 뜻이기 때문입니다. ”

“ 오른쪽이 그 결과입니다. 임계값을 올리면 자동 처리 비율은 줄지만 자동 처리한 것의 정확도는 올라갑니다. ”

“ 저희가 검증셋에서 고른 지점은 0.53입니다. 여기서 들어온 사진의 0.3%, 단 8장만 사람이 확인하면 나머지는 98.8% 정확도로 자동 분류됩니다. ”

“ 쓰레기 분류라는 실제 문제에 가장 잘 맞는 형태의 결론입니다. ”

슬라이드 25 · 90초

검정 34 임계값 조정은 효과가 있었나

24 검정 ③④ 임계값 조정은 효과가 있었나

선택은 검증셋에서, 적용은 test 에 한 번만

검정 ③ 클래스별 가중 argmax

소수 클래스에 유리한 가중치를 곱해 argmax 를 밀었다. 검증셋에서 고른 최적 계수는 0.00 이었다.

	조정 맞춤	조정 틀림
기본 맞춤	2,301	0
기본 틀림	0	33

불일치 0 쌍 — 예측이 한 장도 바뀌지 않아 검정이 성립하지 않는다

검정 ④ 확신도 기반 판단 보류

확신도가 τ 미만이면 사람에게 넘긴다. 자동 처리 구간의 정확도가 전체보다 유의하게 높은지 부트스트랩으로 확인했다.

전체 정확도	0.9859
자동 처리 정확도	0.9884
차이 95% CI	[0.0008, 0.0047]
0 을 포함하지 않는다 — H_0 기각, 보류 규칙이 작동한다	

여기서 가장 중요한 것은 ③ 이 실패했다는 사실

검증셋에서는 가중치가 macro-F1 을 올렸다. 그런데 test 에서는 예측이 한 장도 바뀌지 않았다. 이득이 검증셋에 과적합되어 있었다는 뜻이다.

만약 test 확률에서 임계값을 골랐다면 반드시 미세한 개선이 나왔을 것이고, 그 개선은 허구였을 것이다. 검증셋에서 고르고 test 에 한 번만 적용했기 때문에 이 사실을 확인할 수 있었다.

“ 마지막 검정 두 개입니다. 임계값 조정이 실제로 성능을 올렸는지 확인했습니다. ”

“ 먼저 왼쪽, 검정 3입니다. 소수 클래스에 유리한 가중치를 곱해서 argmax를 미는 방법입니다. 검증셋에서 최적 계수를 찾았더니 0.00이 나왔습니다. 조정을 아예 하지 말라는 뜻이죠. ”

“ 그래도 test에 적용해봤습니다. 표를 보시면 2,301장이 둘 다 맞고, 33장이 둘 다 틀렸습니다. 예측이 바뀐 게 한 장도 없습니다. ”

“ McNemar 검정은 두 예측이 다른 경우만 보는데, 다른 경우가 0건이라 검정 자체가 성립하지 않습니다. ”

“ 오른쪽, 검정 4입니다. 확신도가 기준 미만이면 사람에게 넘기는 방식이죠. 자동 처리 구간의 정확도가 전체보다 유의하게 높은지 부트스트랩으로 확인했습니다. 전체 0.9859, 자동 처리분 0.9884, 차이의 신뢰구간이 0.0008에서 0.0047입니다. 0을 포함하지 않으니 귀무가설을 기각합니다. 보류 규칙은 작동합니다. ”

“ 그런데 이 슬라이드에서 가장 중요한 건 3이 실패했다는 사실입니다. ”

“ 검증셋에서는 가중치가 macro-F1을 올렸습니다. 그런데 test에서는 예측이 한 장도 안 바뀌었습니다. 이득이 검증셋에 과적합되어 있었던 겁니다. ”

“ 만약 저희가 test 확률을 보고 임계값을 골랐다면 어땠을까요. 반드시 미세한 개선이 나왔을 겁니다. 그리고 그 개선은 허구였을 겁니다. ”

“ 검증셋에서 고르고 test에 딱 한 번만 적용했기 때문에 이 사실을 확인할 수 있었습니다. 기법이 통했다는 결과보다, 통하지 않는다는 걸 정직하게 확인한 결과가 방법론적으로 더 값어치 있다고 생각합니다. ”

(이 슬라이드에서 시간을 충분히 쓰세요. 발표 전체에서 가장 강한 부분입니다.)

슬라이드 26 · 40초

정리

25
정리
무엇을 했고, 무엇을 못 했는가

결론

모델을 바꾸는 것보다 데이터를 고치는 게 먼저였다

0.652 → 0.984

모델을 바꿔서 얻은 것

53 건 → 33 건

해상도를 올려서 얻은 것

clothes → shoes 오분류는 데이터를 고쳐서 20 건대에서 0 건이 됐다

아직 못 한 것

1
탐지 임계값은 임의값이다

Hamming 5, 픽셀차 0.05 는 시행착오로 정했다. 값을 바꾸려면 매번 재학습이 필요하다.

2
라벨 검수가 고르지 않다

모델이 확신하며 틀린 것만 후보로 올리므로, 못 배우는 유형의 오류는 놓친다.

3
단일 시드 단일 학습이다

0.005 안팎의 차이는 실행 간 변동 폭 안에 있을 수 있다.

주요 주장 네 개에 통계 검정을 붙였고, 그중 하나는 효과가 없다는 결과가 나왔다. 그것도 결과로 보고한다 — 감추면 나머지 세 개도 믿을 수 없기 때문이다.

“정리하겠습니다.”

“모델을 바꾸는 것보다 데이터를 고치는 게 먼저였습니다.”

“밑바닥 CNN 0.652에서 224px 전이학습 0.984까지 올린 건 분명 큰 변화입니다. 그런데 *clothes* → *shoes* 오분류를 20건대에서 0건으로 만든 건 모델을 전혀 건드리지 않고 얻은 결과입니다.”

“오른쪽은 저희가 아직 못 한 것들입니다.”

“근접중복 탐지 임계값은 시행착오로 정한 값이고, 라벨 검수는 클래스마다 고르지 않으며, 시드 하나로만 학습했습니다. 시드 5회 반복에서 test macro-F1이 ± 0.0046 흔들렸으니 0.005 안팎의 차이는 그 안에 있을 수 있습니다. 세 가지 다 추가 학습 시간이 필요해서 이번 범위에서는 해결하지 못했습니다.”

“마지막으로 한 가지만 더 말씀드리면, 저희는 주요 주장 네 개에 통계 검정을 붙였는데 그중 하나는 효과가 없다는 결과가 나왔습니다. 그것도 결과로 보고했습니다. 감추면 나머지 세 개도 믿을 수 없기 때문입니다.”

“이상 3조 발표를 마치겠습니다. 감사합니다.”

(결론 한 문장을 먼저 말하고 숫자 두 개로 뒷받침하세요. 한계는 빠르게 넘어가되 빠뜨리지 마세요.)

예상 질문과 답변

Q. 왜 EfficientNetV2-S를 골랐나요?

→ 처음에는 밀바닥 CNN과 비교하는 게 목적이었고, 전이학습 모델 중에서는 파라미터 수 대비 성능이 좋다고 알려진 것을 택했습니다. 다만 저희가 여러 백본을 비교한 것은 아니라서, 다른 모델이 더 나을 가능성은 열려 있습니다.

Q. 데이터를 31장이자 뺐는데 성능에 영향이 있었나요?

→ 정확도 숫자로는 거의 차이가 없었습니다. 정제 전 0.9743에서 정제 후 0.9773으로 0.003 올랐는데, 시드 5회 반복에서 측정한 변동 폭(± 0.0046) 안입니다. **효과가 뚜렷하게 보인 건 숫자가 아니라 오분류 패턴이었습니다.** clothes에서 shoes로 틀리는 게 20건대에서 사라졌고, 이걸 실행마다 일관되게 재현됐습니다.

Q. 근접 중복 판정 기준(Hamming 5, 픽셀차 0.05)은 어떻게 정했나요?

→ **시행착오로 정한 값이고, 최적화된 값은 아닙니다.** 느슨하게 잡으면 오탐이 늘고 조이면 진짜 중복을 놓칩니다. 여러 값으로 정제를 반복하려면 매번 재학습이 필요해서 이번 범위에서는 하지 못했습니다. 저희 보고서에도 한계로 명시해뒀습니다.

Q. 라벨 검토 204건이면 전체의 1.3%인데, 나머지에는 오류가 없다고 확신하나요?

→ 확신할 수 없습니다. 저희 방법은 **모델이 확신하며 틀린 것만 후보로 올리기 때문에, 모델이 애초에 잘 못 배우는 유형의 오류는 놓칩니다.** 실제로 정제 후 재평가에서 새로운 라벨 오류 후보 2건이 추가로 발견됐습니다. 한 번의 진단으로 다 잡을 수 없다는 걸 확인한 셈입니다.

Q. clothes에 정정이 몰린 게 그 클래스에 오류가 많아서인가요?

→ **그렇다고 단정할 수 없습니다.** 검수 자체가 그쪽에 집중됐기 때문일 수도 있습니다. 이 둘은 저희 방법으로는 구분되지 않고, 방법론의 구조적 맹점이라고 보고 있습니다.

Q. 해상도를 224로 올린 게 가장 큰 개선인데, 왜 처음부터 그렇게 하지 않았나요?

→ 처음에는 학습 시간을 줄이려고 128px로 시작했습니다. 재질이 비슷한 클래스가 계속 헷갈리길래 **질감 정보가 저해상도에서 날아간 게 아닐까** 의심해서 224px로 올려봤고, 실제로 plastic F1이 0.911에서 0.958로 올랐습니다. 정제로 해결되지 않던 문제의 상당 부분이 해상도 문제였던 셈입니다.

Q. 앙상블은 안 해봤나요?

→ 해봤습니다. 128px에서는 3개 학습률 앙상블이 단일모델보다 +0.0119로 뚜렷이 좋았습니다. 그런데 224px에서는 +0.0006으로 시드 노이즈 기준선(± 0.0046)보다 훨씬 작았습니다. 단일모델 성능이 이미 0.98대라 짜낼 여지가 적었던 것으로 보입니다. 추론 비용이 3배인데 얻는 게 노이즈 수준이라 채택하지 않았습니다.

Q. 하이퍼파라미터 튜닝은 얼마나 했나요?

→ 전처리 방식과 불균형 대응을 2x2로 비교했고, 학습률은 128px와 224px에서 각각 3개씩 완전 학습으로 비교했습니다. 시드 5회 반복으로 변동 폭도 측정했는데 test macro-F1 기준 ± 0.0046 이었습니다. **224px에서 lr 1e-4를 채택한 근거가 val 기준 +0.0053이었으니 이 변동 폭을 겨우 넘는 수준입니다.** 실제로 test에서는 +0.0001에 그쳤습니다 — val과 test가 어긋난 사례로 기록해뒀습니다.

Q. 검정 3은 실패했는데 왜 발표에 넣었나요?

→ 그게 이 프로젝트에서 가장 의미 있는 결과 중 하나라고 봅니다. 검증셋에서는 개선이 있었는데 test에서는 없었습니다. 이건 임계값 조정의 이득이 검증셋에 과적합될 수 있다는 걸 보여줍니다. 만약 test에서 임계값을 골랐다면 개선이 나왔을 것이고 그건 허구였을 겁니다. 실패를 감추면 나머지 결과도 못 믿게 됩니다.

Q. 검정 네 개를 왜 발표 중간중간에 흠어났나요?

→ 각 주장 바로 뒤에 그 주장의 근거를 붙이는 게 자연스럽다고 판단했습니다. 뒤로 물면 앞에서 한 이야기를 다시 해야 하고, 청중이 어떤 주장에 대한 검정인지 기억하기 어렵습니다.

Q. 부트스트랩 2,000회, 순열 5,000회는 충분한가요?

→ 순열검정의 p값이 0.0002인데 이걸 5,000회에서 나올 수 있는 최솟값입니다. 더 늘리면 더 작아지겠지만 결론은 같습니다. 부트스트랩도 2,000회면 95% 신뢰구간이 안정적으로 수렴합니다. 다만 **정확한 p값이 필요한 상황이라면 순열 횟수를 늘려야 합니다.**

Q. 실제 서비스에 쓸 수 있나요?

→ macro-F1 0.979면 나쁘지 않지만 그대로 쓰기는 어렵습니다. **확신도 0.53 미만인 0.3%를 사람이 확인하는 구조라면 98.8% 정확도로 운영 가능합니다.** 다만 이 데이터셋이 제품 사진 위주라, 실제 수거 현장의 더러워지고 찌그러진 쓰레기에는 성능이 떨어질 가능성이 큼니다.

발표 전 체크리스트

Noto Sans CJK KR 폰트가 발표 PC에 설치돼 있는지 (없으면 PDF로 발표)

슬라이드 6(정확도의 함정), 23(EDA 연결), 25(검정 3 실패)에서 한 박자 쉬기

파트 교대 지점 3곳에서 다음 발표자 이름 부르기

파트 시간: 김태경 5분 · 이현중 6분 · 박병찬 6분 (도입 1분 20초 포함 총 18분)

혼동행렬(22번)은 글씨가 작으니 화면에서 손으로 짚어가며 설명

검정 슬라이드(9·21·25)는 p값보다 그래프의 '떨어져 있음'을 먼저 말하기