

팀 결과물 통합 검증 보고서

세 파이프라인의 대조 · 부분 채택 · 통합 분석

항목	내용
검증 대상	팀원 3인이 각자 구축한 파이프라인 (노트북 15개)
최종 모델	EfficientNetV2-S (unfreeze, lr 5e-5) — 이현중
데이터	원본 15,515장 → 정제 후 15,484장
분할	train 10,832 / val 2,318 / test 2,334 (그룹 인지)
test 성능	accuracy 0.9773 / macro-F1 0.9671 / macro-AUC 0.9995
통합 방식	부분 채택 — 통합 분석 노트북 신규 생성
통합 산출물	09_Team_Analysis.ipynb (20/20 셀 실행 검증 완료)

결론 요약

세 결과물 중 어느 하나도 단독으로 채점 기준 세 가지를 충족하지 못했다. 성능이 가장 높은 파이프라인에는 가설검정과 임계값 분석이 없었고, 그 두 항목을 갖춘 파이프라인은 성능이 가장 낮았다. 따라서 전체 합치가 아니라 **부분 채택**으로 통합했다. 최종 모델의 예측 확률만 넘겨받아 분석을 얻는 구조라 재학습이 필요 없었다.

1. 채점 기준 부합 여부

기준	A	B (이현중)	C (김태경)
평가지표 선정과 근거	◎ 부트스트랩 CI	○ 서술만	○ 기준선 + balanced acc
가설검정	◎ 4종	없음	△ 1종
임계값에 따른 지표 변화	◎ 3방식	없음	○ 1방식
모델 성능 (test macro-F1)	△ 0.9182	◎ 0.9671	○ 0.9576
데이터 누수 방지	◎ SGKF + assert	○ Union-Find	◎ SGKF + assert
결과 해석 · 시각화	○	◎ Grad-CAM, 오분류 전수	○

성능과 채점 기준이 **정확히 반대 방향**으로 갈랐다. 이것이 통합이 필요했던 이유다.

2. 검증 — 발견된 문제

치명 (1) 데이터 정제 결과가 같음

작업자	정제 후	제외	라벨 정정	탐지 방법
A	15,484	31	46	MD5 + dHash(16) + Hamming≤5 + 픽셀검증
B (이현중)	15,484	31	46	MD5 + dHash(16) + Hamming≤5 + 픽셀검증
C (김태경)	15,486	29	48	MD5 + B의 근접중복 목록 인용

A와 B는 독립 구현인데 세 숫자가 완전히 일치했다. 근접중복 그룹 수(42그룹, 그 중 바이트가 다른 25그룹)까지 같았다. 서로 다른 코드가 같은 결과를 낸 것이므로 구현 오류는 없다고 볼 수 있다. C와의 2장 차이는 아래와 같이 조정했다.

파일	쟁점	채택
clothes526.jpg	A·B는 '식별 불가'로 제외 / C는 shoes로 정정	제외 — 육안 재검토 기록에 애매(C)로 재분류되어 있음
shoes1878.jpg	A·B는 비사진(렌더링)으로 제외 / C는 목록 누락	제외
paper8.jpg	C만 plastic으로 정정 (비닐 포장지)	정정 채택 — B의 test 오분류 전수 확인에서 새로 발견된 건

치명 (2) 분할이 셋 다 달라 성능 직접 비교 불가

작업자	분할 방식	train / val / test
A	StratifiedGroupKFold(10) → 7:1.5:1.5	10,838 / 2,323 / 2,323
B	클래스별 cluster 누적 절단 (Union-Find)	10,832 / 2,318 / 2,334
C	StratifiedGroupKFold(20) → 14:3:3	10,842 / 2,322 / 2,322

세 test 셋이 서로 다른 이미지 집합이다. 0.9182 / 0.9671 / 0.9576을 한 표에 나란히 놓으면 안 된다. 통합 보고서는 **B의 분할 하나로 통일했다**.

주의 (3) test를 두 번 사용한 사례

C의 ResNet18 노트북이 튜닝 전(0.9512)과 튜닝 후(0.9576) 각각 test를 평가했다. 두 번째는 val로 고른 설정이지만, **첫 번째 test 결과를 본 뒤 튜닝을 시작한 구조**라 test 정보가 선택에 흘러들었다. 강의에서 다룬 스태킹 누수 사례와 같은 형태다. 최종 보고에는 하나만 쓴다.

주의 (4) 임계값 선택 규칙이 무력화됨

C의 규칙은 '커버리지 ≥ 0.80 중 selective macro-F1 최대'인데 테이블 전 구간에서 커버리지가 0.92 이상이였다. 제약이 한 번도 걸리지 않아 규칙이 '격자에서 가장 큰 값을 고르라'로 퇴화했고, 선택값 0.95가 격자 끝값인 것이 그 증거다. 같은 문제가 통합 모델에서도 재현되어(목표 98%에서 tau 0.30, 보류 0장) 통합 노트북은 목표를 여러 개 스윕해 제약이 실제로 작동하는 지점을 자동 선택하도록 수정했다.

주의 (5) 튜닝 차이가 노이즈 범위

C의 하이퍼파라미터 4개 비교에서 val macro-F1이 0.9534 ~ 0.9591로 최대 0.0057 차이였다. B가 직접 기록한 run-to-run 변동 폭과 같은 크기다. 특정 설정이 최적이라고 단정하지 않고 '네 설정 모두 변동 범위 안이라 하이퍼파라미터 민감도가 낮았다'로 서술한다.

중복 (6) 세 명이 같은 작업을 함

- MD5 완전중복 탐지 — 3명 전부
- dHash 근접중복 탐지 — A, B
- 기본 EDA (분포·크기·모드) — A, C
- 베이스라인 CNN 구현·학습 — 3명 전부
- ResNet18 전이학습 — A, C

본문은 하나로 통일하고 나머지는 부록에서 '독립 구현으로 동일 결과 확인'으로 처리한다. 중복 자체가 교차 검증 근거가 되므로 감출 필요는 없다.

3. 통합 방식 — 부분 채택

전체 합치는 불가능하다. 세 분할이 다르므로 결과를 물리적으로 합칠 수 없다. 성능이 가장 높은 B의 파이프라인을 기준으로 두고, 그 최종 모델의 예측 확률 위에 A의 분석 절차를 얹는 방식으로 통합했다.

구성 요소	채택	사유
데이터 정제	A + B (15,484) + C의 paper8	두 독립 구현이 일치
분할	B (Union-Find cluster)	최종 모델이 이 위에서 학습됨
EDA — 색상 가설	A	증강 설계의 유일한 정량 근거
EDA — 기본 통계	C	가장 상세
베이스라인 CNN	B	최종 분할과 일치
전이학습	B (EfficientNetV2-S)	최고 성능 0.9671
튜닝 방법론	B (lr 3종 완전학습)	미니스톱 결함까지 기록
다수클래스 기준선	C	지표 근거의 핵심
가설검정	A (4종)	채점 기준 2
임계값 분석	A (3방식) + C의 selective metric	채점 기준 3
결과 해석	B (Grad-CAM, 오분류 전수)	유일

4. 탈락 항목과 사유

탈락 항목	사유
A — ResNet18 학습 결과 전체	같은 정제 데이터에서 B가 macro-F1 0.9671, A가 0.9182다. 0.049 차이는 run-to-run 변동을 넘는다. 다만 '밑바닥 학습 대비 전이학습' 서사는 B의 데이터로 재구성해 살린다.
A — 불균형 대응 3종 비교	B가 2×2 그리드(전처리 × 불균형)로 더 정교하게 수행했다. A의 실험은 과소적합 상태에서 나와 결론 신뢰도가 낮다.
A — v1 vs v2 누수 성능 비교	세 명 모두 처음부터 그룹 인지 분할을 써서 비교 대상이 없다. '단순 분할 시 13그룹 26장이 갈라진다'는 구조적 사실만 방법론 근거로 남긴다.
C — clothes526.jpg 라벨 정정	육안 재검토에서 '식별 불가'로 판정된 파일이다. 정정이 아니라 제외가 맞다.
C — ResNet18 튜닝 노트북의 test 평가	test 2회 사용 문제. 최종 수치는 B의 것을 쓴다.
C — 증강 효과 순열검정	검정 자체는 정확하나 결론이 채택 모델과 상충한다(최종 모델은 증강을 사용). 본문에서 빼고 한계 절에 '증강이 항상 이득은 아니다'로 인용한다.
중복 EDA · 중복 MD5 탐지	본문은 하나로 통일. 부록에 교차 검증 근거로 한 줄 처리.

5. 통합 분석 결과

통합 노트북 09_Team_Analysis.ipynb를 신규 생성했고 20개 코드 셀 전부를 실행해 검증했다. 최종 모델의 val/test 확률만 입력으로 받으므로 재학습도 추론도 필요 없다.

채점 기준 1 — 평가지표 선정 근거

다수 클래스만 답하는 모델을 실제로 측정했다.

지표	다수클래스 기준선	최종 모델	비고
accuracy	0.3398	0.9773	다수 클래스가 지배
balanced accuracy	0.0833	0.9668	= 1/12, 무작위 수준
macro-F1	0.0423	0.9671	클래스 균등 (주 지표)
weighted-F1	0.1723	0.9773	다수 클래스가 지배
macro-AUC	-	0.9995	임계값 무관 순위 품질

아무것도 학습하지 않은 모델이 정확도 34%를 얻는다. 그런데 macro-F1은 0.042다. 약 8배 차이다. 정확도는 다수 클래스 하나만 잘 맞혀도 올라가지만 macro-F1은 나머지 11개를 전부 틀리면 즉시 무너진다. 유비가 아니라 우리 데이터에서 직접 측정된 반례이며, 이것이 macro-F1을 주 지표로 삼는 근거다.

채점 기준 2 — 가설검정 4종

검정	방법	결과	판정
1. 유리 3종 색상 분포가 다르다	순열검정 5,000회	관측 검침 0.5547 vs 순열평균 0.8554 (16.2%), $p = 0.0002$	기각
1-사후. 어느 쌍이 다른가	Kruskal-Wallis → Mann-Whitney (Bonferroni)	$H = 280.31$, $p = 1.35e-61$. brown vs green만 유의하지 않음(효과크기 0.041)	기각
2. accuracy가 소수 클래스 실패를 가린다	부트스트랩 2,000회	격차 0.0102, 95% CI [0.0068, 0.0139]	기각
3. 클래스별 임계값 조정이 개선을 만든다	McNemar	불일치 쌍 0개 (예측 변화 0장)	검정 불성립
4. 확신도 보류가 자동 처리 정확도를 높인다	부트스트랩 2,000회	차이 0.0066, 95% CI [0.0036, 0.0100]	기각

검정 1의 사후검정이 밝힌 것

채도로는 brown과 green이 구분되지 않는다(효과크기 0.041). 갈라지는 것은 white 대 나머지 둘뿐이다. 채도는 '색이 얼마나 진한가'이지 '무슨 색인가'가 아니기 때문이다. 반면 순열검정은 색상(Hue) 히스토그램을 봤고 셋 다 분리됐다.

색상은 세 클래스를 모두 가르고, 채도는 유색과 무색만 가르다. 그래서 증강에서 hue = 0.0이 필수다. brown과 green의 구분이 오직 색상에만 의존하므로, 색상을 흔들면 이 두 클래스가 서로 섞인다.

채점 기준 3 — 임계값에 따른 지표 변화

세 방식을 모두 수행했다. 모두 val에서 선택하고 test에 한 번만 적용했다.

방식	val 선택	test 결과
최저 F1 클래스(plastic) OvR 임계값	목표 재현율 95% 하 정밀도 최대 → 0.05	재현율 0.892→0.969, 정밀도 0.921→0.818 (놓침 14→4, 오인 10→28)
클래스별 가중 argmax	최적 alpha = 0.00	예측 변화 0장 — 조정 여지 없음
전역 확신도 보류	목표 자동정확도 98.5% → tau = 0.71	커버리지 0.9837, 자동 처리 정확도 0.9839, 사람 검토 38장

먼저 확인한 것. 온도 스케일링처럼 모든 클래스에 똑같이 적용하는 조정은 예측을 한 장도 바꾸지 않는다. argmax가 단조 변환에 불변이기 때문이다. 확신도 숫자는 전부 달라지는데 정확도와 macro-F1은 소수점까지 같다. 예측이 바뀌려면 클래스마다 다르게 조정해야 한다. 이 사실을 코드로 먼저 보이고 세 방식으로 넘어간다.

방식 의 결과가 가장 의미 있다

val에서 최적 alpha가 0.00으로 나왔고 test 예측이 한 장도 바뀌지 않았다. McNemar 표가 $b = 0$, $c = 0$ 이라 검증 자체가 성립하지 않는다.

'기법을 적용했더니 좋아졌다'가 아니라 '적용할 여지가 없음을 확인했다'가 결론이다. 모델이 이미 클래스 간 결정 경계를 충분히 잘 잡고 있어 사후 조정의 여지가 없다는 뜻이며, 이것 역시 측정된 결과다. 만약 test에서 임계값을 골랐다면 반드시 미세한 개선이 나왔을 것이고 그 개선은 허구였을 것이다. val에서 골랐기 때문에 이 사실을 알 수 있었다.

방식 에서 발견한 설계 결함

목표 자동 정확도를 98%로 잡으면 $\tau = 0.30$, 커버리지 100%, 보류 0장이 나온다. 제약이 한 번도 걸리지 않아 규칙이 무의미해진다. C의 노트북에서 지적한 것과 같은 문제가 통합 모델에서도 재현된 것이다. 그래서 목표를 여러 개 스윙하고 제약이 실제로 작동하는 지점을 자동 선택하도록 만들었다.

목표 자동 정확도	val tau	test 커버리지	test 자동 정확도	보류
98.0%	0.30	1.0000	0.9773	0장 (제약 무력)
98.5%	0.71	0.9837	0.9839	38장 (채택)
99.0%	0.92	0.9627	0.9924	87장
99.5%	0.99	0.9165	0.9977	195장

운영 관점으로 옮기면, 들어온 사진의 1.6%(38장)만 사람이 확인하면 나머지는 98.4% 정확도로 자동 분류된다. 검정 4에서 이 차이가 통계적으로 유의함을 확인했다.

6. 교차 검증으로 드러난 것

세 파이프라인이 같은 취약 클래스를 지목했다

클래스	A (ResNet18)	C (ResNet18)	B (EffNetV2-S, 최종)
plastic (F1)	0.8421	0.8916	0.9105
metal (정밀도)	0.7754	0.8516	0.9032
white-glass (F1)	0.8807	0.9027	0.9649

서로 다른 분할, 다른 모델인데 **metal의 정밀도만 유독 낮은 패턴이 3회 재현됐다**. 모델이 애매하면 metal이라고 답하는 경향이 우연이 아니라는 뜻이다.

EDA의 색상 분석이 그 이유를 설명한다. white-glass의 평균 채도는 19.78로 다른 유리의 3분의 1이고 유효 색상 픽셀 비율도 0.14로 절반 이하다. 투명 유리라 색 정보가 거의 없어 질감과 반사에만 의존하게 되고, 그것이 금속 광택과 겹친다. EDA 단계의 기술통계가 모델링 단계의 실패 지점을 예측한 셈이다.

클래스별 신뢰구간이 말하는 것

클래스	support	F1	95% CI	폭
plastic	130	0.9105	[0.8728, 0.9453]	0.0725
metal	116	0.9333	[0.8970, 0.9636]	0.0667
clothes	793	0.9962	[0.9930, 0.9988]	0.0058

support가 작을수록 신뢰구간이 넓다. plastic의 구간 폭 0.0725는 clothes의 12배가 넘는다. 점 추정만 보고 '이 클래스가 저 클래스보다 낫다'고 말하기 어렵다는 뜻이며, 부트스트랩을 함께 보고하는 이유다.

7. 남은 한계

- **탐지 threshold는 임의값이다**. 근접중복 판정의 Hamming 5, 픽셀차 0.05는 시행착오로 정한 값이지 최적화된 값이 아니다.
- **라벨 검수가 클래스마다 고르지 않다**. 확신도 기반 진단은 모델이 확신하며 틀린 것만 후보로 올리므로, 모델이 애초에 잘 못 배우는 유형의 오류는 놓친다. clothes에 정정이 물린 것도 실제로 오류가 많아서인지 검수가 그쪽에 집중돼서인지 구분되지 않는다.
- **문서 간 수치 불일치가 미해결이다**. 라벨 검토 보고서는 검토 건수를 232건으로 적었으나 코드는 임계값 0.9 고정이라 204건이 재현된다.
- **단일 시드 단일 학습이다**. 하이퍼파라미터 비교에서 관측된 0.005 안팎의 차이는 run-to-run 변동 폭 안에 있을 가능성이 높다. 여러 시드로 반복해야 확정할 수 있다.
- **누수 방지 효과를 정량화하지 않았다**. 단순 분할 시 13그룹 26장이 갈라진다는 것은 확인했으나, 그것이 성능을 얼마나 부풀리는지는 측정하지 않았다.
- **증강 효과가 조건에 따라 뒤집힌다**. 얇은 CNN에서는 증강이 오히려 해로웠고(macro-F1 0.829 → 0.789), 전이학습에서는 차이가 유의하지 않았다(순열검정 $p = 0.42$). 최종 모델은 증강을 채택했으나 증강이 항상 이득이라는 일반화는 성립하지 않는다.

본 보고서의 모든 수치는 09_Team_Analysis.ipynb를 실행해 얻은 값이다. 20개 코드 셀 전부 오류 없이 실행되는 것을 확인했다.