

팀 결과물 통합 검증 보고서

세 파이프라인의 대조 · 부분 채택 · 통합 분석

항목	내용
검증 대상	팀원 3인이 각자 구축한 파이프라인 (노트북 15개)
최종 모델	EfficientNetV2-S (unfreeze, lr 5e-5) — 이현중
데이터	원본 15,515장 → 정제 후 15,484장
분할	train 10,832 / val 2,318 / test 2,334 (그룹 인지)
test 성능	accuracy 0.9773 / macro-F1 0.9671 / macro-AUC 0.9995
통합 방식	부분 채택 — 통합 분석 노트북 신규 생성
통합 산출물	09_Team_Analysis.ipynb (20/20 셀 실행 검증 완료)

결론 요약

세 결과물 중 어느 하나도 단독으로 채점 기준 세 가지를 충족하지 못했다. 성능이 가장 높은 파이프라인에는 가설검정과 임계값 분석이 없었고, 그 두 항목을 갖춘 파이프라인은 성능이 가장 낮았다. 따라서 전체 합치가 아니라 **부분 채택**으로 통합했다. 최종 모델의 예측 확률만 넘겨받아 분석을 얻는 구조라 재학습이 필요 없었다.

1. 채점 기준 부합 여부

기준	A	B (이현중)	C (김태경)
평가지표 선정과 근거	◎ 부트스트랩 CI	○ 서술만	○ 기준선 + balanced acc
가설검정	◎ 4종	없음	△ 1종
임계값에 따른 지표 변화	◎ 3방식	없음	○ 1방식
모델 성능 (test macro-F1)	△ 0.9182	◎ 0.9671	○ 0.9576
데이터 누수 방지	◎ SGKF + assert	○ Union-Find	◎ SGKF + assert
결과 해석 · 시각화	○	◎ Grad-CAM, 오분류 전수	○

성능과 채점 기준이 **정확히 반대 방향**으로 갈랐다. 이것이 통합이 필요했던 이유다.

2. 검증 — 발견된 문제

치명 (1) 데이터 정제 결과가 같음

작업자	정제 후	제외	라벨 정정	탐지 방법
A	15,484	31	46	MD5 + dHash(16) + Hamming≤5 + 픽셀검증
B (이현중)	15,484	31	46	MD5 + dHash(16) + Hamming≤5 + 픽셀검증
C (김태경)	15,486	29	48	MD5 + B의 근접중복 목록 인용

A와 B는 독립 구현인데 세 숫자가 완전히 일치했다. 근접중복 그룹 수(42그룹, 그 중 바이트가 다른 25그룹)까지 같았다. 서로 다른 코드가 같은 결과를 낸 것이므로 구현 오류는 없다고 볼 수 있다. C와의 2장 차이는 아래와 같이 조정했다.

파일	쟁점	채택
clothes526.jpg	A·B는 '식별 불가'로 제외 / C는 shoes로 정정	제외 — 육안 재검토 기록에 애매(C)로 재분류되어 있음
shoes1878.jpg	A·B는 비사진(렌더링)으로 제외 / C는 목록 누락	제외
paper8.jpg	C만 plastic으로 정정 (비닐 포장지)	정정 채택 — B의 test 오분류 전수 확인에서 새로 발견된 건

치명 (2) 분할이 셋 다 달라 성능 직접 비교 불가

작업자	분할 방식	train / val / test
A	StratifiedGroupKFold(10) → 7:1.5:1.5	10,838 / 2,323 / 2,323
B	클래스별 cluster 누적 절단 (Union-Find)	10,832 / 2,318 / 2,334
C	StratifiedGroupKFold(20) → 14:3:3	10,842 / 2,322 / 2,322

세 test 셋이 서로 다른 이미지 집합이다. 0.9182 / 0.9671 / 0.9576을 한 표에 나란히 놓으면 안 된다. 통합 보고서는 **B의 분할 하나로 통일했다**.

주의 (3) test를 두 번 사용한 사례

C의 ResNet18 노트북이 튜닝 전(0.9512)과 튜닝 후(0.9576) 각각 test를 평가했다. 두 번째는 val로 고른 설정이지만, **첫 번째 test 결과를 본 뒤 튜닝을 시작한 구조**라 test 정보가 선택에 흘러들었다. 강의에서 다룬 스태킹 누수 사례와 같은 형태다. 최종 보고에는 하나만 쓴다.

주의 (4) 임계값 선택 규칙이 무력화됨

C의 규칙은 '커버리지 ≥ 0.80 중 selective macro-F1 최대'인데 테이블 전 구간에서 커버리지가 0.92 이상이였다. 제약이 한 번도 걸리지 않아 규칙이 '격자에서 가장 큰 값을 고르라'로 퇴화했고, 선택값 0.95가 격자 끝값인 것이 그 증거다. 같은 문제가 통합 모델에서도 재현되어(목표 98%에서 tau 0.30, 보류 0장) 통합 노트북은 목표를 여러 개 스윙해 제약이 실제로 작동하는 지점을 자동 선택하도록 수정했다.

주의 (5) 튜닝 차이가 노이즈 범위

C의 하이퍼파라미터 4개 비교에서 val macro-F1이 0.9534 ~ 0.9591로 최대 0.0057 차이였다. B가 직접 기록한 run-to-run 변동 폭과 같은 크기다. 특정 설정이 최적이라고 단정하지 않고 '네 설정 모두 변동 범위 안이라 하이퍼파라미터 민감도가 낮았다'로 서술한다.

중복 (6) 세 명이 같은 작업을 함

- MD5 완전중복 탐지 — 3명 전부
- dHash 근접중복 탐지 — A, B
- 기본 EDA (분포·크기·모드) — A, C
- 베이스라인 CNN 구현·학습 — 3명 전부
- ResNet18 전이학습 — A, C

본문은 하나로 통일하고 나머지는 부록에서 '독립 구현으로 동일 결과 확인'으로 처리한다. 중복 자체가 교차 검증 근거가 되므로 감출 필요는 없다.

3. 통합 방식 — 부분 채택

전체 합치는 불가능하다. 세 분할이 다르므로 결과를 물리적으로 합칠 수 없다. 성능이 가장 높은 B의 파이프라인을 기준으로 두고, 그 최종 모델의 예측 확률 위에 A의 분석 절차를 얹는 방식으로 통합했다.

구성 요소	채택	사유
데이터 정제	A + B (15,484) + C의 paper8	두 독립 구현이 일치
분할	B (Union-Find cluster)	최종 모델이 이 위에서 학습됨
EDA — 색상 가설	A	증강 설계의 유일한 정량 근거
EDA — 기본 통계	C	가장 상세
베이스라인 CNN	B	최종 분할과 일치
전이학습	B (EfficientNetV2-S)	최고 성능 0.9671
튜닝 방법론	B (lr 3종 완전학습)	미니스톱 결함까지 기록
다수클래스 기준선	C	지표 근거의 핵심
가설검정	A (4종)	채점 기준 2
임계값 분석	A (3방식) + C의 selective metric	채점 기준 3
결과 해석	B (Grad-CAM, 오분류 전수)	유일

4. 탈락 항목과 사유

탈락 항목	사유
A — ResNet18 학습 결과 전체	같은 정제 데이터에서 B가 macro-F1 0.9671, A가 0.9182다. 0.049 차이는 run-to-run 변동을 넘는다. 다만 '밑바닥 학습 대비 전이학습' 서사는 B의 데이터로 재구성해 살린다.
A — 불균형 대응 3종 비교	B가 2×2 그리드(전처리 × 불균형)로 더 정교하게 수행했다. A의 실험은 과소적합 상태에서 나와 결론 신뢰도가 낮다.
A — v1 vs v2 누수 성능 비교	세 명 모두 처음부터 그룹 인지 분할을 써서 비교 대상이 없다. '단순 분할 시 13그룹 26장이 갈라진다'는 구조적 사실만 방법론 근거로 남긴다.
C — clothes526.jpg 라벨 정정	육안 재검토에서 '식별 불가'로 판정된 파일이다. 정정이 아니라 제외가 맞다.
C — ResNet18 튜닝 노트북의 test 평가	test 2회 사용 문제. 최종 수치는 B의 것을 쓴다.
C — 증강 효과 순열검정	검정 자체는 정확하나 결론이 채택 모델과 상충한다(최종 모델은 증강을 사용). 본문에서 빼고 한계 절에 '증강이 항상 이득은 아니다'로 인용한다.
중복 EDA · 중복 MD5 탐지	본문은 하나로 통일. 부록에 교차 검증 근거로 한 줄 처리.

5. 통합 분석 결과

통합 노트북 09_Team_Analysis.ipynb를 신규 생성했고 20개 코드 셀 전부를 실행해 검증했다. 최종 모델의 val/test 확률만 입력으로 받으므로 재학습도 추론도 필요 없다.

채점 기준 1 — 평가지표 선정 근거

다수 클래스만 답하는 모델을 실제로 측정했다.

지표	다수클래스 기준선	최종 모델	비고
accuracy	0.3398	0.9773	다수 클래스가 지배
balanced accuracy	0.0833	0.9668	= 1/12, 무작위 수준
macro-F1	0.0423	0.9671	클래스 균등 (주 지표)
weighted-F1	0.1723	0.9773	다수 클래스가 지배
macro-AUC	-	0.9995	임계값 무관 순위 품질

아무것도 학습하지 않은 모델이 정확도 34%를 얻는다. 그런데 macro-F1은 0.042다. 약 8배 차이다. 정확도는 다수 클래스 하나만 잘 맞혀도 올라가지만 macro-F1은 나머지 11개를 전부 틀리면 즉시 무너진다. 유비가 아니라 우리 데이터에서 직접 측정된 반례이며, 이것이 macro-F1을 주 지표로 삼는 근거다.

채점 기준 2 — 가설검정 4종

검정	방법	결과	판정
1. 유리 3종 색상 분포가 다르다	순열검정 5,000회	관측 검침 0.5547 vs 순열평균 0.8554 (16.2%), $p = 0.0002$	기각
1-사후. 어느 쌍이 다른가	Kruskal-Wallis → Mann-Whitney (Bonferroni)	$H = 280.31$, $p = 1.35e-61$. brown vs green만 유의하지 않음(효과크기 0.041)	기각
2. accuracy가 소수 클래스 실패를 가린다	부트스트랩 2,000회	격차 0.0102, 95% CI [0.0068, 0.0139]	기각
3. 클래스별 임계값 조정이 개선을 만든다	McNemar	불일치 쌍 0개 (예측 변화 0장)	검정 불성립
4. 확신도 보류가 자동 처리 정확도를 높인다	부트스트랩 2,000회	차이 0.0066, 95% CI [0.0036, 0.0100]	기각

검정 1의 사후검정이 밝힌 것

채도로는 brown과 green이 구분되지 않는다(효과크기 0.041). 갈라지는 것은 white 대 나머지 둘뿐이다. 채도는 '색이 얼마나 진한가'이지 '무슨 색인가'가 아니기 때문이다. 반면 순열검정은 색상(Hue) 히스토그램을 봤고 셋 다 분리됐다.

색상은 세 클래스를 모두 가르고, 채도는 유색과 무색만 가르다. 그래서 증강에서 hue = 0.0이 필수다. brown과 green의 구분이 오직 색상에만 의존하므로, 색상을 흔들면 이 두 클래스가 서로 섞인다.

채점 기준 3 — 임계값에 따른 지표 변화

세 방식을 모두 수행했다. 모두 val에서 선택하고 test에 한 번만 적용했다.

방식	val 선택	test 결과
최저 F1 클래스(plastic) OvR 임계값	목표 재현율 95% 하 정밀도 최대 → 0.05	재현율 0.892→0.969, 정밀도 0.921→0.818 (놓침 14→4, 오인 10→28)
클래스별 가중 argmax	최적 alpha = 0.00	예측 변화 0장 — 조정 여지 없음
전역 확신도 보류	목표 자동정확도 98.5% → tau = 0.71	커버리지 0.9837, 자동 처리 정확도 0.9839, 사람 검토 38장

먼저 확인한 것. 온도 스케일링처럼 모든 클래스에 똑같이 적용하는 조정은 예측을 한 장도 바꾸지 않는다. argmax가 단조 변환에 불변이기 때문이다. 확신도 숫자는 전부 달라지는데 정확도와 macro-F1은 소수점까지 같다. 예측이 바뀌려면 클래스마다 다르게 조정해야 한다. 이 사실을 코드로 먼저 보이고 세 방식으로 넘어간다.

방식 의 결과가 가장 의미 있다

val에서 최적 alpha가 0.00으로 나왔고 test 예측이 한 장도 바뀌지 않았다. McNemar 표가 $b = 0$, $c = 0$ 이라 검증 자체가 성립하지 않는다.

'기법을 적용했더니 좋아졌다'가 아니라 '적용할 여지가 없음을 확인했다'가 결론이다. 모델이 이미 클래스 간 결정 경계를 충분히 잘 잡고 있어 사후 조정의 여지가 없다는 뜻이며, 이것 역시 측정된 결과다. 만약 test에서 임계값을 골랐다면 반드시 미세한 개선이 나왔을 것이고 그 개선은 허구였을 것이다. val에서 골랐기 때문에 이 사실을 알 수 있었다.

방식 에서 발견한 설계 결함

목표 자동 정확도를 98%로 잡으면 $\tau = 0.30$, 커버리지 100%, 보류 0장이 나온다. 제약이 한 번도 걸리지 않아 규칙이 무의미해진다. C의 노트북에서 지적한 것과 같은 문제가 통합 모델에서도 재현된 것이다. 그래서 목표를 여러 개 스윙하고 제약이 실제로 작동하는 지점을 자동 선택하도록 만들었다.

목표 자동 정확도	val tau	test 커버리지	test 자동 정확도	보류
98.0%	0.30	1.0000	0.9773	0장 (제약 무력)
98.5%	0.71	0.9837	0.9839	38장 (채택)
99.0%	0.92	0.9627	0.9924	87장
99.5%	0.99	0.9165	0.9977	195장

운영 관점으로 옮기면, 들어온 사진의 1.6%(38장)만 사람이 확인하면 나머지는 98.4% 정확도로 자동 분류된다. 검정 4에서 이 차이가 통계적으로 유의함을 확인했다.

6. 교차 검증으로 드러난 것

세 파이프라인이 같은 취약 클래스를 지목했다

클래스	A (ResNet18)	C (ResNet18)	B (EffNetV2-S, 최종)
plastic (F1)	0.8421	0.8916	0.9105
metal (정밀도)	0.7754	0.8516	0.9032
white-glass (F1)	0.8807	0.9027	0.9649

서로 다른 분할, 다른 모델인데 **metal의 정밀도만 유독 낮은 패턴이 3회 재현됐다**. 모델이 애매하면 metal이라고 답하는 경향이 우연이 아니라는 뜻이다.

EDA의 색상 분석이 그 이유를 설명한다. white-glass의 평균 채도는 19.78로 다른 유리의 3분의 1이고 유효 색상 픽셀 비율도 0.14로 절반 이하다. 투명 유리라 색 정보가 거의 없어 질감과 반사에만 의존하게 되고, 그것이 금속 광택과 겹친다. EDA 단계의 기술통계가 모델링 단계의 실패 지점을 예측한 셈이다.

클래스별 신뢰구간이 말하는 것

클래스	support	F1	95% CI	폭
plastic	130	0.9105	[0.8728, 0.9453]	0.0725
metal	116	0.9333	[0.8970, 0.9636]	0.0667
clothes	793	0.9962	[0.9930, 0.9988]	0.0058

support가 작을수록 신뢰구간이 넓다. plastic의 구간 폭 0.0725는 clothes의 12배가 넘는다. 점 추정만 보고 '이 클래스가 저 클래스보다 낫다'고 말하기 어렵다는 뜻이며, 부트스트랩을 함께 보고하는 이유다.

증강 효과는 모델 용량에 따라 갈렸다

모델	증강 미적용	증강 적용	검정
얇은 CNN (BaseCNN)	0.8291	0.7888	증강이 오히려 해로움
ResNet18 전이학습	0.9538	0.9547	순열검정 $p = 0.4247$, 유의하지 않음

val macro-F1 기준이다. 얇은 CNN에서는 증강이 성능을 **0.040 떨어뜨렸고**, 전이학습에서는 차이가 유의하지 않았다.

그럼에도 최종 모델이 증강을 채택한 것은 모순이 아니다. 최종 설정은 증강 단독이 아니라 **전처리 방식 × 불균형 대응의 2×2 그리드**에서 'ratio 유지 크롭 + WeightedRandomSampler' 조합이 val macro-F1 최고(0.7633)였기 때문에 선택된 것이다. 증강 유무와는 다른 층위의 결정이다.

여기서 얻는 교훈은 **증강이 항상 이득이라는 통념이 성립하지 않는다**는 것이다. 모델 용량이 부족한 상태에서 입력을 흔들면 학습이 더 어려워진다. 관행을 그대로 따르지 않고 실제로 비교한 것이 이 결과를 드러냈다.

7. 남은 한계

- **탐지 threshold는 임의값이다**. 근접중복 판정의 Hamming 5, 픽셀차 0.05는 시행착오로 정한 값이지 최적화된 값이 아니다. 느슨하게 잡으면 오탐이 늘고 조이면 진짜 중복을 놓친다. 여러 값으로 정제를 반복하려면 매번 재학습이 필요해 이번 범위에서는 수행하지 못했다.

- **라벨 검수가 클래스마다 고르지 않다.** 확신도 기반 진단은 모델이 확신하며 틀린 것만 후보로 올리므로, 모델이 애초에 잘 못 배우는 유형의 오류는 놓친다. clothes에 정정이 몰린 것도 실제로 오류가 많아서인지 검수가 그쪽에 집중돼서인지 구분되지 않는다. 이 방법론의 구조적 맹점이다.
- **단일 시드 단일 학습이다.** 하이퍼파라미터 비교에서 관측된 0.005 안팎의 차이는 run-to-run 변동 폭 안에 있을 가능성이 높다. 여러 시드로 반복해야 특정 설정이 우수하다고 확정할 수 있으며, 본 보고서는 그 대신 '민감도가 낮았다'고만 서술한다.
- **누수 방지의 효과를 정량화하지 않았다.** 단순 분할 시 근접중복 13그룹 26장이 갈라진다는 구조적 사실은 확인했으나, 그것이 성능을 얼마나 부풀리는지는 측정하지 않았다. 측정하려면 누수가 있는 분할로 전체를 다시 학습해야 한다.
- **분할을 팀 내에서 통일하지 못했다.** 세 사람이 각자 다른 분할을 만들어 작업한 탓에 세 모델을 같은 test 셋에서 직접 비교할 수 없었고, 본 보고서는 성능 비교를 최종 모델 하나로 제한해야 했다. 정제 직후 분할 CSV를 먼저 공유하고 시작했다면 피할 수 있었던 문제다. 협업 절차상의 교훈으로 남긴다.

본 보고서의 모든 수치는 09_Team_Analysis.ipynb를 실행해 얻은 값이며, 20개 코드 셀 전부 오류 없이 실행되는 것을 확인했다. 위 한계 다섯 가지는 모두 추가 학습 시간이 필요한 항목이라 이번 범위에서는 해결하지 않고 명시적으로 기록하는 쪽을 택했다.